

Prédire le risque de départ de feu à l'échelle communale en France métropolitaine

Rapport scientifique Romuald Courtois · M1 Data / IA · La Plateforme_ Marseille · 2026

Résumé

Le danger météorologique de feu de forêt est publié en France sur une maille de $0,25^\circ$, soit environ 28 km de côté. À l'intérieur d'une telle maille se trouvent en moyenne 31 communes, qui reçoivent le même indice qu'elles soient couvertes de maquis ou entièrement bétonnées. Ce travail cherche à savoir si l'on peut estimer, à l'échelle du couple commune $\times$ jour et à partir des seules données publiques disponibles en temps réel, la probabilité qu'un départ de feu soit déclaré.

Une grille dense de 253 731 870 couples commune $\times$ jour a été construite sur 2006-2025 en croisant quatre sources publiques. Huit familles de modèles ont été comparées sur un découpage strictement temporel, au moyen d'un bootstrap apparié rééchantillonnant les communes plutôt que les lignes.

Le modèle retenu atteint un lift de 63,7 sur une période de test ouverte une seule fois, contre 42,1 pour la meilleure règle sans apprentissage. Trois résultats méritent d'être signalés. D'abord, trois des cinq modèles comparés sont statistiquement indiscernables entre eux, ce qui invalide toute hiérarchie qu'on aurait pu en tirer. Ensuite, un réseau récurrent optimisé perd 23,6 % contre un modèle à variables physiques agrégées, à information égale, et trois analyses indépendantes convergent pour expliquer pourquoi. Enfin, le modèle mis en service n'est délibérément pas le plus performant : le meilleur dépend d'une variable qui n'existera pas au moment de la prédiction.

Mots-clés : événement rare, classification spatio-temporelle, indices de danger météorologique, estimation sur petits domaines, interprétabilité, validation croisée spatiale.

1. Introduction

1.1 Contexte

Les feux de forêt en France métropolitaine suivent deux saisons distinctes, et non une seule. Le pic estival, méditerranéen, est le plus connu. Un second pic apparaît en mars dans le Sud-Ouest et le Massif central, sur des landes et des herbacées sèches avant la reprise de végétation, souvent à la suite d'écobuages qui échappent. Sur les 52 809 feux déclarés au fichier BDIFF entre 1973 et 2025 sur le périmètre d'étude, la part survenant hors saison estivale atteint 52 % dans le Cantal, 44 % en Dordogne et 41 % en Lozère. Un modèle n'apprenant que l'été manquerait environ un feu sur cinq.

Cette bimodalité impose de traiter la saisonnalité comme une variable explicative et non comme un filtre appliqué en amont.

1.2 L'existant et sa limite

Le *Fire Weather Index* et les sept autres indices du système canadien sont calculés quotidiennement par le Copernicus Emergency Management Service et diffusés sur une grille régulière de $0,25^\circ$. Ils décrivent

l'inflammabilité de l'air et du combustible : c'est une information météorologique, et elle est de bonne qualité.

Sa limite est spatiale. La France métropolitaine est couverte par 1 131 cellules pour 34 734 communes, soit environ 31 communes par cellule. Deux communes partageant une cellule reçoivent un indice identique alors que leur couvert végétal, leur relief et leur densité de population peuvent tout opposer. La météo indique quand ; elle n'indique pas où.

L'apport visé n'est donc pas de remplacer ces indices, qui constituent l'entrée principale du modèle, mais de leur adjoindre une description du territoire à une résolution que le maillage météorologique n'atteint pas.

1.3 Question de recherche

Peut-on estimer, à l'échelle du couple commune $\times$ jour, la probabilité qu'un départ de feu soit déclaré, à partir des seules données publiques disponibles en temps réel ?

La restriction finale est une contrainte que l'étude s'impose, et elle détermine le modèle mis en service. Quatre hypothèses en découlent, formulées de façon à pouvoir être réfutées.

H1. La météorologie seule ne suffit pas à localiser le risque.

H2. Le territoire porte une information que la météorologie ne contient pas, et cette information se transfère à des zones non observées.

H3. Une architecture séquentielle n'apporte rien de plus que des indices physiques agrégés.

H4. Le danger météorologique augmente de façon détectable sur cinquante ans d'observation.

H3 est énoncée dans le sens qui permet sa réfutation : si le réseau récurrent l'avait emporté, il aurait été déployé.

2. Données

2.1 Sources

Quatre jeux de données publics ont été croisés.

Le **CEMS Copernicus** fournit huit indices de danger quotidiens par cellule de 0,25° sur 1973-2025, soit 21,9 millions de lignes. Outre le FWI, il publie le *Fine Fuel Moisture Code* (litière de 1 à 2 cm), le *Duff Moisture Code* (5 à 10 cm), le *Drought Code* (10 à 20 cm), le *Build-Up Index*, l'*Initial Spread Index*, le *Keetch-Byram Drought Index* et l'*Energy Release Component*.

La **BDIFF**, tenue par l'IGN, recense les feux déclarés commune par commune. 52 809 d'entre eux tombent dans le périmètre d'étude.

CORINE Land Cover décrit l'occupation du sol en 44 postes, dont huit décrivent la végétation susceptible de brûler, pour 1,08 million de lignes.

Le référentiel **INSEE** fournit la liste des communes et, ce qui s'est révélé indispensable, le fichier officiel des mouvements de communes.

2.2 Unité d'analyse

L'unité retenue est le couple **commune × jour**, et la cible est binaire : au moins un départ de feu déclaré ce jour-là dans cette commune.

Ce choix a une conséquence qu'il faut énoncer. Un incendie traversant cinq communes produit cinq observations positives. La quantité modélisée n'est donc pas le nombre d'incendies mais le nombre de communes-jours touchés, ce qui est une approximation acceptable pour un problème de ciblage mais interdit toute lecture en nombre de sinistres.

2.3 Appariement et difficulté rencontrée

Le rattachement des feux aux communes s'est heurté aux fusions de communes. 965 feux portent un code INSEE qui n'existe plus dans le référentiel courant.

Un rapprochement par similarité de nom a d'abord été tenté, puis abandonné : il produisait des faux positifs, la commune de Chirac en Lozère se voyant rattachée à son homonyme de Charente. Le coût d'une telle erreur est élevé et diffus, puisqu'elle corrompt simultanément la cible, le voisinage et les variables d'occupation du sol de communes qui n'ont rien à voir avec le sinistre.

Le fichier officiel des mouvements de communes de l'INSEE a donc été téléchargé et appliqué. 935 feux ont été rattachés avec certitude. Les 30 restants, soit 0,68 % du total concerné, ont été **écartés et comptés**. Perdre une fraction connue vaut mieux qu'en inventer une inconnue.

2.4 Limites de la cible

La BDIFF n'est pas exhaustive et le rapport ne le dissimule pas. Sa couverture varie selon les départements et les périodes, et **64 % des causes déclarées sont manquantes**. Un contrôle a été mené sur la qualité des dates, en vérifiant l'absence de déficit le dimanche qui aurait signalé une date de saisie administrative plutôt qu'une date d'éclosion.

Ces limites portent sur la variable à prédire, et non sur les variables explicatives. Elles bornent donc ce que l'étude peut prétendre mesurer, et non seulement sa précision.

3. Méthode

3.1 Construction de la grille

La table centrale contient une ligne par commune et par jour, qu'un feu s'y soit déclaré ou non, soit 253 731 870 lignes pour 49 130 positifs sur 2006-2025. Elle est stockée dans PostgreSQL 16 avec l'extension PostGIS, partitionnée par année.

Conserver les jours sans feu multiplie le volume par cinq mille. Ce coût est assumé pour une raison technique précise : une série creuse rend les fenêtres glissantes silencieusement fausses. La variable « nombre de feux dans les trente jours précédents » se calcule en remontant trente lignes ; si les jours sans feu sont absents, on remonte en réalité plusieurs années, et aucune exception n'est levée.

Le partitionnement par année n'est pas cosmétique non plus : il fait coïncider la frontière physique du stockage avec la frontière du découpage temporel.

3.2 Protocole d'évaluation

Le découpage est **temporel**, jamais aléatoire : entraînement sur 2006-2019, validation sur 2020-2022, test sur 2023-2025.

Partition	Années	Lignes	Feux	Taux
entraînement	2006-2019	177 594 942	33 632	0,0189 %
validation	2020-2022	38 068 464	9 176	0,0241 %
test	2023-2025	38 068 464	6 322	0,0166 %

Un découpage aléatoire placerait le 14 juillet 2019 dans l'entraînement et le 15 dans le test ; le modèle prédirait un événement observé la veille à vingt kilomètres, et la métrique serait excellente sans que le modèle ait aucune valeur.

Les cas ambigus ont été tranchés par une règle explicite : *une variable datée peut consulter tout le passé, y compris celui de sa propre période d'évaluation ; une statistique non datée ne peut consulter que l'entraînement*. Ainsi « feux des trente jours précédents » évalué au 3 août 2023 lit juillet 2023 sans constituer une fuite, puisque cette information est effectivement disponible au matin du 3 août, tandis qu'un « taux moyen de la commune sur toute la période » consulterait le futur.

Le jeu de test a été ouvert **une seule fois**, après gel documenté du modèle, des variables et de la calibration, daté du 28 juillet 2026. La justification de cette rigidité est que le risque associé à un jeu de test est cumulatif : chaque consultation en révèle un peu, et les décisions ultérieures en sont insensiblement informées.

3.3 Métrique

À un taux de base de 0,019 %, l'exactitude est inutilisable : un classifieur constant négatif atteint 99,98 %. Aucune mesure d'exactitude n'est rapportée.

L'aire sous la courbe précision-rappel a été retenue de préférence à l'aire sous la courbe ROC. Cette dernière vaut 0,50 au hasard quel que soit le déséquilibre et devient flatteuse lorsque les négatifs sont cinq mille fois plus nombreux : l'ajout de faux positifs ne déplace presque pas le taux de faux positifs. La PR-AUC vaut en revanche exactement le taux de base sous l'hypothèse nulle, ce qui autorise la définition d'un rapport interprétable :

$$\text{lift} = \text{PR-AUC} \div \text{taux de base}$$

3.4 Sous-échantillonnage

L'entraînement sur 177 millions de lignes étant impraticable, les négatifs de la partition d'entraînement ont été **échantillonnés à 0,187 %**, tous les positifs étant conservés, ce qui produit un ratio approximatif de un pour dix. Aucune donnée n'est ajoutée ni dupliquée. Le tirage est déterministe et donc reproductible.

Les techniques de sur-échantillonnage par interpolation n'ont pas été retenues. Les variables décrivant des propriétés physiques du territoire, interpoler entre deux communes éloignées produirait des combinaisons qui n'existent pas.

Cette opération déplace le prior : le modèle apprend sur une population à 9,1 % de positifs quand la population réelle en compte 0,019 %, soit un facteur 487. Trois précautions en découlent. Les partitions de validation et de test ne sont jamais échantillonnées, ce qui préserve la comparabilité des scores au monde réel. Les statistiques dérivées de la cible sont calculées sur l'entraînement complet et non sur l'échantillon, faute de quoi tout lissage hériterait d'un prior faux d'un facteur 487 sans qu'aucune métrique ne le signale. Enfin la calibration absorbe le décalage résiduel.

3.5 Variables

Le modèle le plus complet compte 52 variables, réparties en cinq familles : indices météorologiques du jour et de la veille, occupation du sol, morphologie du territoire (altitude, amplitude altimétrique, superficie, distance à la côte), démographie, et calendrier avec encodage cyclique du jour de l'année.

Une étude d'ablation a testé l'ajout de dix décalages météorologiques supplémentaires, portant le jeu à 62 variables. Le gain mesuré est de **+0,02 %** et les variables ajoutées ne captent que **3,3 %** de l'importance totale. Elles n'ont pas été retenues. Ce résultat sera repris en discussion : il constitue un premier indice que la profondeur temporelle n'apporte rien à ce problème.

3.6 Estimation sur petits domaines

Le diagnostic du premier modèle est sans ambiguïté : 54,6 % de son importance provient de l'historique de sinistralité de la commune. Il énonce essentiellement que ce qui a brûlé brûlera de nouveau. Cette proposition est vraie mais laisse une lacune : une commune n'ayant jamais brûlé conserve un score faible même lorsqu'elle est entourée de communes qui brûlent chaque été. 73 % des communes françaises, soit 25 297, sont dans ce cas sur la période d'étude.

Il s'agit du problème classique de l'estimation sur petits domaines : les événements sont trop rares pour estimer un taux commune par commune.

La réponse retenue procède en deux temps. Les communes sont d'abord regroupées selon leurs caractéristiques **physiques** (végétation, relief, densité, climatologie du FWI, position) par un algorithme des k-moyennes à trente groupes. La cible n'intervient à aucun moment dans cette étape, faute de quoi la construction serait circulaire. Les coordonnées géographiques sont incluses mais pondérées à 25 %, dosage qui maintient la cohérence spatiale des groupes sans les réduire à un découpage administratif. Deux communes dépourvues de profil exploitable sont affectées à un groupe résiduel recevant le taux national.

Un lissage bayésien hiérarchique fait ensuite converger le taux de chaque commune vers celui de son groupe :

$$\text{taux_commune} = (\text{nb_feux} + K_1 \times \text{taux_du_groupe}) / (\text{nb_jours} + K_1)$$

avec $K_1 = 2\,000$ et, un niveau au-dessus, $K_0 = 20\,000$ pour le rappel du groupe vers le taux national. La constante K s'interprète comme un nombre de jours fictifs. Chaque commune disposant de 5 113 jours d'entraînement, le poids accordé au groupe s'établit à 28,1 %.

Trois garde-fous protègent cette étape de la fuite. Les profils ne consultent que le passé, soit CORINE 2006 et la climatologie 2006-2019. Les taux sont agrégés sur l'entraînement complet. Enfin, pour une observation d'entraînement de l'année Y , les taux **excluent l'année Y** , ce qui neutralise la fuite classique de l'encodage par la cible.

3.7 Modèles comparés

Huit familles ont été évaluées, chacune répondant à une question précise : trois règles sans apprentissage servant de référence, un gradient boosting standard, sa version optimisée, sa version enrichie du lissage, une variante à abandon d'arbres, un perceptron multicouche, un modèle restreint aux variables physiques, et un réseau récurrent à mémoire longue recevant trente jours de huit indices.

Les hyperparamètres du gradient boosting ont été recherchés par optimisation bayésienne (Optuna, échantillonnage TPE, 60 essais). Ceux du réseau récurrent l'ont été de la même façon sur 25 essais, avec arrêt précoce déclenché à la vingt-et-unième époque.

3.8 Protocole de comparaison

Un écart de PR-AUC entre deux modèles ne constitue pas un résultat tant que l'incertitude qui l'entoure n'est pas quantifiée. Un **bootstrap apparié** a donc été mis en œuvre : les deux modèles comparés sont évalués sur exactement les mêmes lignes rééchantillonnées, deux cents fois, ce qui donne accès à la distribution de l'écart et non à deux distributions marginales.

Le rééchantillonnage porte sur les **communes** et non sur les lignes. Les 1 096 observations quotidiennes d'une commune ne sont pas indépendantes, et trente-et-une communes partagent la même cellule météorologique. Un rééchantillonnage ligne à ligne traiterait 38 millions d'observations comme autant d'expériences indépendantes et produirait des intervalles de confiance trop étroits, conduisant à conclure à des différences inexistantes. Il s'agit d'une pseudo-réplication.

Le coût de calcul a été maîtrisé en triant les scores une seule fois : une réplique se réduit alors à un vecteur de poids entiers le long d'un ordre figé, et la précision moyenne pondérée se calcule en une passe par sommes cumulées. L'équivalence numérique avec l'implémentation de référence a été vérifiée à 10^{-12} près.

4. Résultats

4.1 Références sans apprentissage

Prédicteur	PR-AUC	lift
hasard	0,000241	1,0
historique de la commune	0,004668	19,4
danger EFFIS seul	0,001220	5,1
historique × danger EFFIS	0,010149	42,1

La météorologie seule atteint un lift de 5,1. Croisée à l'historique spatial, elle atteint 42,1. Cet écart constitue une première réponse à **H1** et fixe le seuil au-delà duquel un modèle appris devient utile.

4.2 Progression des modèles

Mesures sur la validation, 38 068 464 lignes et 9 176 feux.

Modèle	PR-AUC	lift
Forêt aléatoire	0,014950	62,0
Gradient boosting v1	0,016593	68,8
v2, hyperparamètres optimisés	0,017463	72,4
v3, avec lissage bayésien	0,017684	73,4
Abandon d'arbres (DART)	0,017360	72,0
Perceptron multicouche	0,017340	71,9
Modèle physique, 41 variables	0,011174	46,4
Réseau récurrent, 30 jours	0,008542	35,4

L'apport du lissage bayésien s'élève à +0,83 %. Il est réel mais modeste, et le rapporter comme tel fait partie du résultat.

Quatre combinaisons d'ensemble ont été évaluées. La meilleure, moyenne de rangs du gradient boosting et du perceptron, atteint 0,018043 soit +2,03 %. Elle n'a pas été retenue, pour des raisons exposées en section 5.3.

4.3 Comparaison appariée

Comparaison	Écart	IC 95 %	Significatif
DART contre v3	-1,8 %	[-5,0 ; +0,8]	non
MLP contre v3	-1,9 %	[-7,9 ; +5,2]	non
Modèle physique contre v3	-36,8 %	[-43,8 ; -24,0]	oui
Réseau récurrent contre v3	-51,7 %	[-57,2 ; -43,4]	oui
Réseau récurrent contre modèle physique	-23,6 %	[-33,5 ; -17,3]	oui

Le résultat le plus instructif de cette section est négatif. Les intervalles associés à l'abandon d'arbres et au perceptron **contiennent zéro** : ces trois modèles sont statistiquement indiscernables. Toute hiérarchie établie entre eux à partir des seules valeurs ponctuelles relèverait du bruit.

Une lecture prudente s'impose : l'absence de significativité n'établit pas l'équivalence, et une puissance statistique supérieure pourrait révéler un écart. L'énoncé défendable est que ce protocole ne permet pas de les départager.

4.4 Le réseau récurrent

À information égale, c'est-à-dire comparé au modèle physique dont il partage l'absence d'historique de sinistralité, le réseau récurrent perd 23,6 %, intervalle [-33,5 ; -17,3]. L'écart est donc solidement établi.

Ce résultat mérite explication, car le réseau dispose d'un volume d'information météorologique vingt fois supérieur : trente jours de huit indices, soit 240 valeurs, contre huit indices du jour et deux décalages pour son concurrent.

L'explication est physique. Les indices DC, DMC et BUI **sont** des états récurrents. Le *Drought Code* est une moyenne exponentielle de la météorologie passée dont la constante de temps vaut 52 jours ; celle du *Duff Moisture Code* vaut 15 jours. C'est la forme fonctionnelle d'une cellule récurrente, à ceci près que ses coefficients ont été calibrés par un demi-siècle de recherche sur le comportement du feu plutôt qu'estimés sur 9 176 exemples positifs. Le service Copernicus livre donc déjà l'état caché que le réseau devrait réapprendre.

Trois analyses indépendantes convergent vers cette conclusion.

L'autocorrélation partielle. Calculée sur les résidus du cycle annuel, 7 305 jours, elle décroît de 0,697 au premier retard à 0,191 au deuxième et 0,077 au troisième, pour un seuil de significativité de 0,023. La mémoire utile de la série est de deux à trois jours. Les retards 4 à 8 demeurent formellement significatifs, mais le retard 8, à 0,034, ne rend compte que de 0,11 % de la variance : la significativité statistique n'implique pas ici l'utilité prédictive.

La modélisation ARIMA. Un modèle autorégressif sans variable exogène produit une corrélation **négative** de -0,118 entre prévision et observation sur l'horizon d'évaluation. À 1 096 pas, un processus dont la mémoire utile vaut trois jours a perdu son point de départ et converge vers sa moyenne ; la trajectoire quasi constante qu'il produit se trouve légèrement anti-corrélée à l'observé. L'introduction du FWI en variable exogène réduit l'erreur absolue moyenne de 37 %.

L'ablation des décalages. L'ajout de dix décalages météorologiques supplémentaires au jeu de variables améliore la PR-AUC de 0,02 % et les nouvelles variables ne captent que 3,3 % de l'importance.

Trois familles de méthodes, une conclusion identique : la prévisibilité du départ de feu réside dans l'état météorologique courant et dans le territoire, non dans la trajectoire temporelle passée.

Réserve. Le réseau récurrent n'a pas reçu la variable *danger_effis*, qui pèse 13,7 % de l'importance du modèle physique. L'écart de 23,6 % constitue donc un majorant, et la levée de cette asymétrie est le premier travail à reprendre.

4.5 Ablation du regroupement territorial

Configuration	Groupes obtenus	Gain relatif
aucun regroupement	—	référence
k-moyennes, k = 10	11	+0,216 %
k-moyennes, k = 30	31	+0,199 %
k-moyennes, k = 60	61	+0,095 %
k-moyennes, k = 120	121	+0,078 %
HDBSCAN	5	+0,022 %

Le gain décroît avec le nombre de groupes, ce qui est cohérent avec la logique de l'estimation sur petits domaines : au-delà d'un certain découpage, chaque groupe redevient trop peu peuplé pour stabiliser l'estimation.

La configuration à dix groupes obtient un gain marginalement supérieur à celle à trente. L'écart, de 0,017 point de pourcentage, ne saurait être considéré comme significatif au vu de la variabilité observée ailleurs

dans cette étude, et le choix de trente groupes a été conservé pour la granularité descriptive qu'il offre à l'application. Ce choix n'est pas justifié par la performance.

HDBSCAN, appliqué avec un paramétrage visant une trentaine de groupes, n'en produit que cinq et obtient le gain le plus faible. La structure du territoire français ne présente apparemment pas la séparation en densité que cet algorithme recherche.

4.6 Transfert spatial

Une validation croisée par région a été conduite : chaque région est retirée de l'entraînement, le modèle est réajusté, puis évalué sur la seule région exclue. L'opération simule un territoire jamais observé.

Le modèle restreint aux variables physiques l'emporte sur le modèle complet dans les **neuf régions sur neuf**, avec un gain moyen pondéré de 8,2 % et un maximum de 137 % en Grand Est.

Ce résultat répond directement à **H2**. Là où l'historique de sinistralité est le plus pauvre, s'y fier devient un handicap : la variable prend la valeur zéro, que le modèle interprète comme une absence de risque plutôt que comme une absence d'information. Les variables de territoire, elles, conservent leur pouvoir prédictif hors du domaine d'apprentissage.

4.7 Calibration

Le score brut surestime la probabilité d'un facteur 144,7, conséquence directe du sous-échantillonnage.

La régression logistique de Platt ramène ce biais à 1,13 sans coût mesurable en PR-AUC, et préserve les neuf millions de valeurs distinctes du score. La régression isotonique atteint une qualité de calibration comparable mais réduit le score à 136 valeurs distinctes, ce qui détruit le pouvoir de discrimination à l'intérieur de chaque palier.

Ces calibrations n'ont finalement pas été employées dans l'application publiée : le calibrateur disponible ayant été ajusté sur un autre modèle et une autre période, il serait faux d'un facteur voisin de deux. L'application affiche un **rang** plutôt qu'une probabilité, choix documenté et non omission.

4.8 Évaluation finale

Sur la période 2023-2025, ouverte une seule fois :

Modèle	PR-AUC	lift
Gradient boosting v3, 52 variables	0,0156	93,8
Modèle physique, 41 variables	0,0106	63,7

La décomposition par année révèle une variation du simple au double, qui suit la rareté plutôt que le hasard.

Année	Feux	lift
2023	2 591	75,6
2024	1 297	151,4
2025	2 434	87,0

L'année la plus calme produit le meilleur lift. Une interprétation cohérente est qu'une saison peu active concentre les départs dans les configurations les plus prévisibles, tandis qu'une saison intense en produit également là où le modèle ne les attend pas.

4.9 Rendement opérationnel

Le lift ne se traduit pas directement en décision. La quantité pertinente pour un service opérationnel est le rappel atteint sous contrainte de budget de surveillance.

Budget	Communes-jours suivis	Feux couverts	Rappel
0,1 %	38 068	924	14,6 %
1 %	380 684	2 650	41,9 %
10 %	3 806 846	5 372	85,0 %

En surveillant un centième du territoire-temps, le modèle couvre 42 % des départs.

Ce cadrage éclaire d'un jour différent l'écart de 37 % de PR-AUC séparant les deux modèles : il ne vaut que **trois points de rappel** à 1 % de budget, et devient nul à 10 %. Une part importante de l'écart mesuré est opérationnellement invisible.

4.10 Tendance climatique

Série	Période	Variation	p	Conclusion
FWI moyen annuel	1973-2025	+58 %	$4,2 \times 10^{-5}$	significatif
FWI moyen juin-septembre	1973-2025	+62 %	$1,5 \times 10^{-4}$	significatif
jours de danger élevé	1973-2025	+197 %	$5,2 \times 10^{-5}$	significatif
communes-jours en feu	2006-2025	+3 %	0,89	non significatif

L'aléa météorologique augmente de manière très significative sur cinquante-deux années d'observation, ce qui répond affirmativement à **H4**. Le nombre de départs, mesuré sur vingt années seulement, ne présente aucune tendance détectable.

Trois lectures restent compatibles avec ces observations : une puissance statistique insuffisante sur vingt points, une politique de prévention absorbant pour l'instant la hausse de l'aléa, ou un déplacement du bilan vers des sinistres plus étendus plutôt que plus nombreux. **Les données mobilisées ici ne permettent pas de trancher**, et il serait abusif de présenter la première série sans la seconde.

5. Interprétation

5.1 Ce que le modèle a appris

Les contributions ont été décomposées par la méthode TreeSHAP, exacte sur un modèle à base d'arbres. Sa correction a été vérifiée : la somme des contributions augmentée de la valeur de base restitue le logarithme des cotes du score à $9,5 \times 10^{-7}$ près.

Trois mesures d'importance ont été confrontées, et elles ne produisent pas le même classement. L'importance par gain, sortie par défaut de l'implémentation, mesure la réduction de perte obtenue à l'entraînement ; elle est biaisée en faveur des variables qui séparent proprement et **aveugle à la redondance**. Les contributions moyennes sur échantillon aléatoire décrivent le territoire tel qu'il est, à 99,97 % exempt de feu. Les contributions au sommet du classement décrivent le comportement du modèle là où il s'engage.

Deux désaccords éclairent le fonctionnement du modèle. La classe de danger EFFIS occupe le deuxième rang par gain et le trentième par contribution moyenne : cette variable est une discrétisation du FWI en six classes, dont les seuils nets facilitent le découpage, mais l'information sous-jacente est déjà présente dans le FWI continu auquel la décomposition en attribue le crédit. La part de maquis occupe le premier rang par gain, le dixième sur échantillon aléatoire et le deuxième au sommet : elle ne déplace rien sur une commune-jour ordinaire, où le maquis est absent, et devient déterminante là où le modèle identifie du risque.

Il en résulte qu'aucune assertion sur « la variable la plus importante » n'a de sens sans spécification de la mesure employée et de la population considérée.

La lecture d'ensemble confirme **H1** et **H2** conjointement : les variables de territoire occupent le haut du classement à parité avec les indices météorologiques. La météorologie situe le moment, le territoire situe le lieu.

Une précaution méthodologique mérite d'être signalée. La sélection des observations sur le score constitue un conditionnement sur un collisionneur, le score étant causé conjointement par la météorologie et le territoire. Une analyse d'interaction menée sur le seul sommet du classement produisait un signe inversé. Le panneau correspondant n'est donc interprété que pour la question « lorsque le risque est élevé », jamais pour une relation générale.

5.2 Analyse contrefactuelle

La génération de contrefactuels répond à une question distincte : non pas pourquoi ce score, mais que faudrait-il modifier pour l'infléchir.

Une difficulté d'implémentation a dû être levée. L'outil recherche par défaut un basculement de la classe prédite au seuil de 0,5. Le score n'étant pas calibré, ce seuil correspond à un niveau de risque inatteignable et aucune solution n'était retournée. La frontière a été recentrée sur le décile par une transformation affine par morceaux strictement croissante, qui laisse le classement inchangé. La question devient alors « que faudrait-il pour sortir des 10 % les plus exposés », qui possède un sens opérationnel.

Appliquée à Bormes-les-Mimosas au 12 août 2024, en n'autorisant que la modification du couvert végétal, la recherche ne retourne **aucune solution**. L'exposition de cette commune tient à sa position, à son relief et à sa superficie, et non à des leviers actionnables. L'absence de contrefactuel constitue ici le résultat.

Un contrefactuel ne saurait au demeurant être lu comme une recommandation. Rien ne garantit sa réalisabilité, ni le caractère causal de la relation : le modèle a estimé des corrélations sur 2006-2019, non des mécanismes.

5.3 Le choix du modèle mis en service

Le modèle le plus performant n'a pas été déployé. Cette décision demande justification.

Le gradient boosting v3 tire 29 % de son importance de l'historique de sinistralité. Or la BDIFF ne publie pas l'année en cours : les sinistres de 2026 seront diffusés au printemps 2027. Une prédiction produite aujourd'hui verrait donc cette variable renseignée par un décompte arrêté à décembre 2025. Elle ne serait pas imprécise, elle serait fausse.

En territoire non observé, la même variable prend la valeur zéro, que le modèle interprète comme une absence de risque là où se manifeste précisément le risque nouveau. La validation croisée spatiale de la section 4.6 quantifie ce phénomène. Enfin, pour toute projection à horizon 2050, la variable est inaccessible par construction.

Ce défaut n'apparaît dans **aucune métrique d'entraînement** : en validation comme en test, l'historique est disponible. Il ne se manifeste qu'en considérant les conditions réelles de mise en service.

La même logique a écarté l'ensemble, malgré son gain de 2,03 % : il double la chaîne de service et rompt la chaîne d'explicabilité, pour un gain qui, à la lumière de la section 4.9, ne se traduirait par aucune amélioration opérationnelle observable.

5.4 Projections

Les projections à horizon 2100 appliquent un facteur multiplicatif issu des trajectoires du GIEC à la climatologie observée sur 2006-2019. La forme du cycle saisonnier provient donc des observations ; seul son niveau est déplacé.

La quantité projetée est l'**aléa météorologique**, et non le nombre de sinistres. Le couvert végétal, les politiques de prévention et les pratiques agricoles sont supposés constants, hypothèse dont on sait qu'elle est fausse.

Avant 2045, les trois trajectoires sont indiscernables. En 2030, la trajectoire la plus sobre dépasse la plus pessimiste sur 59 % des communes. Ce comportement, qui pourrait passer pour une anomalie de calcul, traduit l'inertie du système climatique : les trajectoires d'émissions ne divergent substantiellement qu'après le milieu du siècle. L'application signale explicitement cette zone.

6. Discussion

6.1 Réponses aux hypothèses

H1 est confirmée. La météorologie seule atteint un lift de 5,1 ; croisée au territoire elle atteint 42,1. La décomposition des contributions place les variables de territoire à parité avec les indices météorologiques.

H2 est confirmée. Le modèle restreint aux variables physiques l'emporte dans les neuf régions retirées de l'entraînement, jusqu'à 137 %. Le territoire transfère ; l'historique ne transfère pas.

H3 est confirmée, avec la réserve énoncée en 4.4. Trois familles de méthodes convergent : autocorrélation partielle, modélisation ARIMA, ablation des décalages.

H4 est confirmée pour l'aléa et non vérifiée pour les sinistres. La distinction est essentielle et conditionne toute communication sur ces résultats.

La réponse à la question principale est positive, sous une réserve explicite : l'étude estime un **risque relatif** et non une probabilité absolue.

6.2 Ce que ces résultats ne permettent pas d'affirmer

Le modèle ne prédit pas la surface brûlée, dont le coefficient de détermination atteint 0,144, soit une performance inférieure à celle d'une prédiction constante par la médiane. La surface dépend de ce qui advient **après** le départ : vent, délai d'intervention, relief.

La distinction entre grand et petit sinistre se prédit également mal, avec un lift de 2,88. Une aire sous la courbe ROC de 0,766 peut être calculée sur cette tâche, mais son emploi serait contradictoire avec l'argumentation de la section 3.3.

Le modèle ne prédit pas davantage le nombre de sinistres futurs, ni leur localisation en 2050.

6.3 Menaces sur la validité

Validité interne. Le principal risque est la fuite d'information, d'autant plus insidieuse qu'à ce taux de base elle ne produit aucune erreur détectable mais d'excellentes métriques. Trois protections ont été mises en place et sont testées automatiquement.

Validité de construit. La cible mesure des déclarations, non des occurrences. Le biais de couverture de la BDIFF et les 64 % de causes manquantes affectent ce que l'étude mesure réellement.

Validité externe. Le périmètre est la France métropolitaine ; rien n'autorise l'extrapolation à d'autres contextes. La validation croisée spatiale fournit toutefois un argument en faveur d'une certaine robustesse géographique.

Validité statistique. La corrélation spatiale induite par la maille météorologique a été traitée par le rééchantillonnage au niveau des communes. Elle n'a pas été traitée dans l'estimation des coefficients eux-mêmes, dont les intervalles naïfs seraient trop étroits.

6.4 Erreurs rencontrées

Sur un événement à 0,02 %, une erreur d'implémentation ne se manifeste jamais par une exception mais par une valeur plausible. Deux incidents méritent d'être rapportés pour leur valeur méthodologique.

Le premier verdict porté sur le réseau récurrent annonçait une perte de 97 %, alors que la valeur exacte est de 52 %. L'écart ne provenait pas du modèle mais de la procédure de comparaison. La requête d'assemblage ne comportait pas de clause de tri, l'ordre des 38 millions de lignes retournées dépendant du plan d'exécution et variant d'une exécution à l'autre. Les fichiers de prédictions ne portant que le score et la cible, leur comparaison revenait à les aligner par position. Taille identique, nombre de positifs identique, ordre différent : aucun contrôle ne pouvait le détecter. Depuis, tout fichier de prédictions porte ses clés, une fonction d'alignement les vérifie, et un test refuse tout fichier qui en serait dépourvu.

Le second concerne un modèle secondaire d'estimation de surface, dont le coefficient de détermination atteignait 0,994 et l'aire sous la courbe ROC 1,0000. La cible figurait parmi les variables explicatives. Un résultat trop favorable pour être crédible constitue en soi un signal.

Ces deux incidents illustrent que les seules protections efficaces sont les invariants explicites et les assertions qui échouent bruyamment. Cinquante tests sont exécutés à chaque intégration.

7. Travaux futurs

Par ordre de priorité décroissante :

1. **Lever l'asymétrie de la comparaison au réseau récurrent** en lui fournissant la variable `danger_effis`, afin de transformer le majorant de 23,6 % en estimation.
2. **Recalibrer** le modèle effectivement déployé sur sa propre période, ce qui permettrait d'afficher une probabilité plutôt qu'un rang.
3. **Implémenter la contagion spatiale**, c'est-à-dire le décompte des sinistres survenus dans le voisinage géographique sur une fenêtre glissante. La conception et la requête existent, la table de voisinage est chargée, mais la variable n'a pas été produite et ne figure dans aucun modèle.
4. **Rechercher une source de cause de départ** moins lacunaire que les 64 % de valeurs manquantes actuels, l'origine humaine ou naturelle d'un départ étant vraisemblablement le déterminant manquant le plus important.
5. **Instrumenter la dérive** en production, sur la distribution des indices d'entrée et sur le rappel à budget constant.

8. Conclusion

Ce travail établit qu'un risque de départ de feu peut être estimé utilement à l'échelle communale à partir de données publiques disponibles en temps réel, avec un lift de 63,7 sur une période de test ouverte une seule fois, contre 42,1 pour la meilleure règle sans apprentissage.

Trois enseignements dépassent le cadre du problème traité.

Le premier est que la comparaison de modèles exige un protocole capable de conclure à l'indécision. Trois des cinq modèles comparés se sont révélés indiscernables, résultat qui aurait été présenté comme une hiérarchie sous un protocole moins exigeant.

Le deuxième est qu'une architecture réputée adaptée à un type de données peut être supplantée par des variables issues de la connaissance du domaine, lorsque celles-ci encodent déjà la structure que l'architecture devrait apprendre. Les indices du système canadien constituent un état récursif calibré par cinquante ans de recherche.

Le troisième est que le critère de sélection d'un modèle destiné au service ne se réduit pas à sa performance mesurée. La disponibilité des variables au moment de la prédiction constitue une contrainte que nulle métrique d'entraînement ne révèle.

Enfin, l'étude conclut à une augmentation très significative de l'aléa météorologique sur cinquante-deux années, sans pouvoir conclure à une augmentation du nombre de départs sur les vingt années observées. Cette distinction, souvent escamotée, est maintenue ici sans arbitrage.

Références et sources

- **Copernicus Emergency Management Service**, European Forest Fire Information System, indices de danger journaliers, grille 0,25°, 1973-2025.
- **IGN / BDIFF**, Base de Données sur les Incendies de Forêts en France.
- **CORINE Land Cover**, Copernicus Land Monitoring Service, millésimes 2006, 2012 et 2018.
- **INSEE**, Code Officiel Géographique et fichier des mouvements de communes.
- **GIEC**, trajectoires représentatives de concentration RCP 2.6, 4.5 et 8.5.

- Van Wagner, C. E., *Development and structure of the Canadian Forest Fire Weather Index System*, Forestry Technical Report 35, 1987.
- Lundberg, S. M. et Lee, S.-I., *A Unified Approach to Interpreting Model Predictions*, NeurIPS, 2017.
- Lundberg, S. M. et al., *From local explanations to global understanding with explainable AI for trees*, Nature Machine Intelligence, 2020.
- Ribeiro, M. T. et al., "Why Should I Trust You?" *Explaining the Predictions of Any Classifier*, KDD, 2016.
- Mothilal, R. K. et al., *Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations*, FAT*, 2020.
- Platt, J., *Probabilistic Outputs for Support Vector Machines*, 1999.
- Rashmi, K. V. et Gilad-Bachrach, R., *DART: Dropouts meet Multiple Additive Regression Trees*, AISTATS, 2015.

Annexe A — Reproduire l'étude

```
docker compose up -d          # PostgreSQL 16 + PostGIS
python -m tvfed.charger_ref    # référentiels et voisinage
python -m tvfed.charger_faits  # CEMS, BDIFF, CORINE
python -m tvfed.charger_grille # la grille commune x jour
python -m tvfed.clustering --methode kmeans --k 30
python -m tvfed.matrices       # matrice d'apprentissage
python -m tvfed.modeles        # v1, v2, v3, DART, MLP
python -m tvfed.modele_c       # le modèle déployé
python -m tvfed.lstm           # le réseau récurrent
python -m tvfed.comparer       # bootstrap apparié
python -m tvfed.series         # ADF, ACF/PACF, SARIMAX
python -m tvfed.explications    # SHAP
python -m tvfed.evaluation_test # ouverture du jeu de test
pytest tests/ -q               # 50 tests
```

Annexe B — Artefacts produits

Chaque résultat chiffré du présent rapport provient d'un fichier versionné dans [data/processed/](#). Les principaux :

Fichier	Contenu
baselines.csv	les trois références sans apprentissage
pr_auc_val.csv	performances sur validation
comparaison_appariee.csv	écarts appariés et intervalles de confiance
transfert_spatial.csv	validation croisée par région
calibration_v3.csv	comparaison des calibrations
resultat_test.csv, test_par_annee.csv	évaluation finale
operationnel_test.csv	rappel sous contrainte de budget

Fichier	Contenu
series_adf.csv , series_acf_pacf.csv , series_sarimax.csv	analyse de séries
comparaison_clusters.csv	ablation du regroupement
test_decalages.csv	ablation des décalages météorologiques
modele_taille.csv	modèles secondaires de surface et de grand feu
gel_avant_test.json	date et configuration du gel

Ressources en ligne

- Application : [terre-vent-feu-eau-data.streamlit.app](#)
- Présentation : [hierogifle.github.io/terre-vent-feu-eau-data](#)
- Code source : [github.com/Hierogifle/terre-vent-feu-eau-data](#)