

Plan directeur — Terre, Vent, Feu, Eau, Data

Statut : document vivant. À mettre à jour au fur et à mesure. **Objectif** : prototype de suivi et de prédiction du risque de feu de forêt en France. **Finalité personnelle** : pièce de portfolio / vitrine LinkedIn.

0. Comment utiliser ce document

- Les sections **1 à 3** sont le **contrat**. Elles ne bougent plus une fois validées.
- La section **6** est ton **fil directeur au quotidien**. Tu la coches.
- La section **5** est ta **liste de pièges**. Relis-la avant chaque phase.
- La section **9** (ce qu'on a écarté) est **aussi importante que le reste** : c'est ce qui te fera passer pour un professionnel en soutenance.

Règle d'or du projet : *une question → une figure → une réponse*. Tu ne construis rien sans savoir à quelle question ça répond.

1. Cadrage — le PROBLEM.md

⚠ **À écrire et valider AVANT toute ligne de code**. 30 minutes. C'est la première chose que tu montreras.

Produit 1 — Risque structurel (*livrable principal*)

Élément	Décision
Question	« Quel est le risque de feu de la commune X le jour J ? »
Unité d'observation	commune × jour ⚠ conditionné au test du dimanche, ci-dessous
Cible (target)	Binaire : y = 1 si ≥1 feu enregistré, sinon 0
Entraînement	Grille commune × jour, 2006–2024, downsampling négatif ~1:10
Split	Train ≤2019 · Validation 2020–2022 · Test 2023–2024
Baseline 1	Fréquence historique lissée (bayésien empirique)
Baseline 2	🌀 Danger rating EFFIS seul
Métriques	PR-AUC (discrimination) + Brier + courbe de calibration
Périmètre v1	Méditerranéen : PACA + Occitanie + Corse (~5 800 communes)
Sortie modèle	Probabilité calibrée journalière
Sortie affichage	Agrégation hebdo $1 - \prod(1 - p_j)$ → 6 classes EFFIS

Produit 2 — Risque conjoncturel (*bonus*)

Identique, horizon J+7 — nécessite une **prévision** FWI, pas la réanalyse.

Produit 3 — Curseur climat (*bonus, peu coûteux*)

GLM Poisson + curseur Streamlit +0 / +1 / +2 / +4 °C → recalcul de la carte de risque.

🔔 LA décision ouverte : jour vs semaine

Historique honnête : *commune* × *semaine* était **un choix par défaut, jamais validé**, hérité de la formulation « une valeur par semaine de l'année **par exemple** » qui portait sur **l'affichage**, pas sur le modèle. Il est devenu faux dès qu'on est passé au FWI journalier.

Pourquoi le JOUR est maintenant le défaut

Argument	Verdict
Le FPMC a une latence de quelques heures/jours	À la semaine, l'indice ne veut plus rien dire . On le détruit en le moyennant.
Le FWI est volatil	Un seul jour extrême déclenche le feu. La moyenne hebdo dilue précisément le signal .
Calendrier (14 juillet, week-ends, fériés)	Variables journalières par nature
Hawkes	Processus ponctuel en temps continu → les bacs de 7 jours le cassent
Volumétrie	✗ Faux argument (voir calcul ci-dessous)

Le calcul volumétrique honnête (*périmètre méditerranéen, pas la France entière*)

	Jour	Semaine
Communes	~5 800	~5 800
Pas de temps (2006-2024)	6 935	991
Lignes	~40 M	~5,7 M
Positifs	~80 000	~70 000
Taux de positifs	0,20 %	1,2 %

La ligne qui compte : le nombre de positifs est quasi identique. Passer à la semaine **ne gagne aucun positif** — ça ne fait que supprimer des négatifs. Or **ce qui compte pour l'apprentissage, c'est le nombre ABSOLU de positifs**, pas le taux. Le taux n'affecte que la métrique et la calibration — deux choses déjà gérées.

(Le « 12,7 M/an et 0,03 % » du premier échange était calculé sur la France entière. C'était un épouvantail.)

🎯 La technique qui rend le jour trivial : le downsampling négatif

Garder **100 % des positifs**, échantillonner les négatifs (1:10, 1:50...).

80 000 positifs + 800 000 négatifs = 880 000 lignes ≈ 200 Mo
→ entraînement en ~30 s → 50 itérations par jour

Méthode standard en prédiction de clic et détection de fraude — **exactement ton régime** (événement rare, gros volume).

Correction de la probabilité (formule fermée, si besoin) :

$$p_{\text{vrai}} = p_{\text{modèle}} / (p_{\text{modèle}} + (1 - p_{\text{modèle}})/r)$$
 # r = taux
d'échantillonnage des négatifs

⚠️ **Mais tu n'en auras pas besoin** : **CalibratedClassifierCV** fitté sur une **validation NON échantillonnée** corrige le downsampling automatiquement.

? Le SEUL vrai argument restant — à trancher par les données

La date de la BDIFF est-elle fiable au jour près ?

- Date d'**éclosion** ? de **découverte/alerte** ? de **saisie administrative** ?
- Un feu parti à 23h le 14 est-il enregistré le 14 ou le 15 ?
- La précision est-elle la même sur toutes les décennies ?

Bruit de ±1-2 jours sur la date

Semaine	Absorbé — ±2 jours restent dans la même semaine
Jour	Fatal — le FWI du jour J est apparié à un feu du jour J-2. Le signal se dilue, et rien dans tes métriques ne te le dira.

Analogie STAPS : si ton chronomètre a ±0,5 s d'erreur, tu ne peux pas étudier des effets de 0,2 s. Ce n'est **pas** une question de puissance statistique — c'est le **plancher de résolution de l'instrument**.
Aucun modèle ne récupère une information que la mesure n'a pas capturée.

✅ LE TEST DU DIMANCHE — bloquant, à faire en phase 2

1. Lire les **métadonnées BDIFF** : quel champ exactement ? Y a-t-il une heure ?
2. **Compter les feux par jour de la semaine.**
 - **Creux le week-end** → ⚠️ ce n'est pas que les forêts brûlent moins le dimanche : **c'est que la saisie se fait en semaine.** Date administrative → **repli sur la semaine.**
 - Distribution plate → ✅ date d'éclosion crédible → **le jour est validé.**
3. **Test complémentaire** : pic anormal le 1er du mois → arrondi administratif → même conclusion.

Cette figure est de toute façon dans la phase 2. **Tu l'auras gratuitement.**

La solution qui te donne les deux — modèle ≠ affichage

MODÈLE au JOUR → $p(\text{feu})$ pour chaque commune $\times$ jour
 ↓
 AGRÉGATION à l'AFFICHAGE → $1 - \prod(1 - p_j)$ sur les 7 jours
 = « proba qu'AU MOINS UN des 7 jours parte en feu »
 ↓
 STREAMLIT → « risque de la commune X en semaine 32 »

Tu gardes tout : FWI journalier intact, 14 juillet, week-ends, Hawkes en temps continu — **et** l'affichage hebdomadaire que tu voulais.

2. Décisions actées et leurs justifications

(À relire avant la soutenance : chaque « pourquoi » est une réponse au jury.)

Décision	Pourquoi
Grille commune $\times$ jour	Le FPMC (latence ~ 1 j) et le FWI sont volatils : la moyenne hebdo détruit le signal. La volumétrie n'est pas un obstacle (downsampling). ⚠ <i>Sous réserve du test du dimanche.</i>
Downsampling négatif $\sim 1:10$	100 % des positifs conservés. 880 k lignes, entraînement en 30 s $\rightarrow$ 50 itérations/jour.
Modèle $\neq$ affichage	Le modèle prédit au jour, l'app agrège à la semaine via $1 - \prod(1 - p_j)$. Deux couches, pas un compromis.
La BDIFF ne contient que des feux	$\rightarrow$ il faut construire les négatifs par produit cartésien
PR-AUC, pas accuracy	Événement à $\sim 0,2$ % $\rightarrow$ un modèle qui prédit toujours 0 fait 99,8 % d'accuracy
Split temporel strict	Split aléatoire = feux du futur dans l'entraînement = fuite
LightGBM	Vitesse = nombre d'itérations possibles par jour
GLM Poisson en parallèle	Seul modèle qui extrapole (lien log) $\rightarrow$ indispensable au curseur climat
CEMS, pas ERA5-Land	Le FWI officiel existe déjà, interpolé à midi local (le problème que j'aurais bricolé). 3 jours économisés.
Les 6 indices, pas juste le FWI	FFMC (~ 1 j) $\cdot$ DMC (12 j) $\cdot$ DC (52 j) = trois mémoires temporelles différentes . Le FWI seul les écrase.
HDBSCAN, pas DBSCAN	eps global de DBSCAN inadapté : densité de feux variable d'un facteur 100
SHAP seul	Une méthode d'interprétabilité bien exploitée > quatre survolées

Décision	Pourquoi
Streamlit seul	Un livrable fini et déployé > deux à moitié
Périmètre méditerranéen v1	Complétude BDIFF + c'est là qu'est le signal

3. Architecture en couches

```

COUCHE 1 – GRILLE
  commune × jour, y = 0/1
  (produit cartésien + LEFT JOIN BDIFF + downsampling négatif)
    ↓
COUCHE 2 – FEATURES « ils fabriquent des colonnes »
  HDBSCAN (typologie) · Voisinage (feux à 10/20/50 km)
  Lissage bayésien · Calendrier · sin/cos · lags
  FWI · FFMC · DMC · DC · BUI · ISI
    ↓
COUCHE 3 – MODÈLE
  LightGBM (le socle) · GLM Poisson (curseur climat)
  [bonus : Hawkes]
    ↓
COUCHE 4 – CALIBRATION
  CalibratedClassifierCV sur validation NON échantillonnée
  → probabilité journalière fiable
    ↓
COUCHE 5 – AGRÉGATION AFFICHAGE
  1 -  $\prod(1 - p_j)$  sur 7 jours → 6 classes EFFIS
    ↓
COUCHE 6 – INTERPRÉTATION
  SHAP
  
```

🔑 Le point qui a créé la confusion (à ne pas réoublier)

HDBSCAN n'est pas un modèle. Il vit en **couche 2**. Il fabrique une colonne `cluster_id` + une carte. Il ne concurrence rien. **Tu le fais, point.**

Hawkes et STGNN sont des modèles. Ils vivent en **couche 3** et concurrencent LightGBM. C'est **là seulement** qu'il y a un arbitrage.

Les trois encodent la **même intuition** (la contagion spatiale), mais **à des couches différentes** : HDBSCAN et le voisinage l'encodent *en features, à la main* ; Hawkes et STGNN l'encodent *dans le modèle, nativement*. D'où la confusion initiale — qui était légitime.

4. Données et sources

4.1 BDIFF — la cible

- **URL** : <https://bdiff.agriculture.gouv.fr/incendies>

- **Période** : 1973–2024
- **Granularité** : communale (code INSEE)
- ⚠ **Limite technique** : CSV par paquets de 30 000 lignes → **boucle de téléchargement par département**
- ⚠ **Biais de collecte** (*tu le connais déjà — à documenter explicitement*) : couverture fine de la zone méditerranéenne depuis 1973 (Prométhée), lacunaire ailleurs surtout avant 2006. **Un modèle entraîné là-dessus apprend en partie la géographie de la collecte, pas celle du risque.**
- 🛠 **Ton travail** : correction + adaptation aux normes de recueil en vigueur

4.2 Référentiel géographique

- **Communes + contours** : `admin-express` (IGN) → centroïde **et** surface
- **Codes** : COG de l'INSEE
- **Alternative** : <https://adresse.data.gouv.fr/outils/telechargements>
- 🎯 Sortie attendue : `code_insee` → (`lat`, `lon`, `geom`, `surface_km2`)

4.3 Densité de population

- **Source** : INSEE, un CSV, ~10 minutes
- **Rôle** : proxy de l'origine humaine (9 feux sur 10 sont d'origine humaine, la moitié par imprudence)

4.4 🎯 Danger météo — CEMS Fire danger indices ★ **LA source**

🔔 **DEUX COMPTES à ouvrir aujourd'hui** (*stores différents, configs API différentes*) :

- **CDS** → <https://cds.climate.copernicus.eu>
- **EWDS** → <https://ewds.climate.copernicus.eu> ← **celui-ci d'abord**

`cems-fire-historical-v1` — <https://ewds.climate.copernicus.eu/datasets/cems-fire-historical-v1>

Reconstruction historique complète des conditions météo favorables au départ, à la propagation et à l'entretien des feux. Produit par le CEMS pour l'**EFFIS**, calculé par le modèle **GEFF** sur la réanalyse **ERA5**.

Couverture temporelle	1940 → aujourd'hui
Mise à jour	Quotidienne
Résolution	0,25° × 0,25° (<i>natif : gaussienne réduite N320, ~31 km</i>)
Fréquence	Journalière
Format	NetCDF (<i>prends celui-là, <code>xarray</code> l'ouvre direct</i>) ou GRIB2
DOI	10.24381/cds.0e89c522 + Vitolo et al. (2020), <i>Scientific Data</i>

⚠ **Piège de lecture** : la fiche affiche « Publication date : 2019-09-30 ». **C'est la date de création de la fiche catalogue, PAS la fin des données.** Réflexe : « *Temporal coverage* » = les données · « *Publication date* » = la paperasse.

Variables à prendre (système canadien uniquement — laisse le NFDRS US et le McArthur AU) :

Variable	Ce que c'est	
Fire weather index	Intensité potentielle du front. Non borné, 50 = extrême	★ feature n°1
Danger rating	FWI en 6 classes EFFIS harmonisées européennes	★ échelle d'affichage
Drought code	Couches profondes 10-20 cm. Latence 52 jours , max ~800	🎯 le bijou : la mémoire de la sécheresse longue
Fine fuel moisture code	Litière fine. Échelle 0-99 (seule bornée). Ignition ~70	★
Duff moisture code	Couches 5-10 cm. Latence 12 jours	✓
Build-up index	Combustible total disponible	✓
Initial spread index	Propagation. +13 km/h de vent double sa valeur	✓
Keetch-Byram drought index	Déficit hydrique du sol, 0-200	✓
Fire daily severity index	Transformation exponentielle du FWI	🎯 cf. non-linéarité

🎯 **Deux échelles de référence disponibles — ton app peut afficher les deux :**

- **EFFIS** : 6 classes (très faible → extrême), harmonisées à l'échelle européenne
- **Météo des forêts** : 4 classes, échelle française départementale

En soutenance : pourquoi la France a-t-elle choisi 4 niveaux quand l'Europe en utilise 6 ? → culture métier.

🕒 Définition temporelle : 1 valeur par jour, à MIDI HEURE LOCALE

Le FWI est **défini** à 12h locale. Or midi UTC à Brest ≠ midi UTC à Nice. Le CEMS résout ça par un **collage temporel et spatial** de 24 h de simulations : les champs sont découpés en bandes de 3 h puis concaténés pour représenter les conditions autour de midi local.

Ils documentent honnêtement la limite : des **artefacts apparaissent à l'interface entre deux bandes**. D'où une méthode plus récente de l'ECMWF : **moyenne pondérée entre les deux pas de temps les plus proches** → accord bien meilleur avec le cycle diurne réel, artefacts éliminés.

🎯 **C'est LA validation du choix CEMS.** C'est exactement le piège « le FWI se calcule à midi mais ERA5-Land ne donne que des max/min journaliers » — **ils l'ont résolu proprement, avec deux méthodes successives et de la littérature derrière.**

💡 Les 3 mémoires temporelles — le point clé

Le dataset est journalier, **mais chaque indice encapsule une fenêtre temporelle différente** :

Indice	Couche physique	Latence	Se souvient de...
FFMC	Litière fine, 1-2 cm	~1 jour	hier
DMC	Couches lâches, 5-10 cm	12 jours	les 2 dernières semaines
DC	Couches profondes, 10-20 cm	52 jours	les 2 derniers mois

Les dérivés sont des **combinaisons instantanées** : $ISI = FFMC + vent \cdot BUI = DMC + DC \cdot FWI = ISI + BUI$.

Analogie STAPS, et elle est exacte : c'est un modèle **impulse-response** de charge d'entraînement. Le FFMC = **fatigue aiguë** (24-48 h). Le DC = **charge chronique** (plusieurs semaines). Le FWI = le **ratio aigu/chronique** qui dit si l'athlète est en zone de risque *aujourd'hui*.

Et comme en STAPS : **les deux comptent, et ils ne disent pas la même chose**. Une forêt humide après 2 mois de sécheresse $\neq$ une forêt humide après 2 mois de pluie.

→ **Prends les 6, pas juste le FWI**. Laisse LightGBM apprendre quelle échelle de temps compte, et à quelle saison.

📁 Les seuils ET les couleurs officiels EFFIS

(Extraits de l'exemple de code du guide utilisateur — les cartes telles qu'affichées sur EFFIS et GWIS.)

Classe	Seuil FWI	Couleur
Très faible	0 – 5,2	#84F07F
Faible	5,2 – 11,2	#FFEB3C
Moyen	11,2 – 21,3	#FFB00C
Élevé	21,3 – 38	#FA4F00
Très élevé	38 – 50	#B40000
Extrême	50+	#280923

Ta palette Streamlit est faite. Ta carte aura **exactement** les couleurs de l'EFFIS → reconnaissable au premier coup d'œil, crédibilité immédiate, zéro travail de design.

⚠ **Incohérence dans leur propre doc** : le FFMC est « 0-101 » dans un paragraphe et « 0-99 » dans le tableau ; le FWI est « 0-100 » ici et « non borné » là. **Fie-toi à `df.describe()`, pas à la doc**.

Argument massue (version corrigée) : « J'ai croisé la BDIFD avec le produit officiel de danger météo du CEMS/EFFIS — celui qui alimente le système européen d'information sur les feux de forêt. » **Savoir trouver et brancher la bonne source EST une compétence. Réimplémenter un indice qui existe déjà n'en est pas une.**

4.5 Météo brute — ERA5-Land ⚠ en COMPLÉMENT seulement

derived-era5-land-daily-statistics (sur le CDS) — 0,1° (~9 km), 1950 → aujourd'hui, NetCDF.

Utile **uniquement** pour :

- `2m_temperature` → **le curseur climat en a besoin** (le GLM Poisson tourne sur la température)
- `volumetric_soil_water_layer_1` → humidité du sol, si tu veux compléter

Variable	⚠ Piège
<code>2m_temperature</code>	En Kelvin → - 273.15
<code>2m_dewpoint_temperature</code>	→ humidité relative (à combiner avec T et pression)
<code>10m_u_component_of_wind</code>	⚠ Ce n'est PAS la vitesse , c'est la composante Est
<code>10m_v_component_of_wind</code>	⚠ idem, composante Nord
<code>volumetric_soil_water_layer_1</code>	Volume d'eau, couche 0-7 cm

```
# Le vent : ERA5 donne 2 composantes vectorielles, pas une vitesse
vitesse_vent = np.sqrt(u10**2 + v10**2)           # m/s
direction    = (180 + np.degrees(np.arctan2(u10, v10))) % 360 # degrés
```

🚩 Les 3 pièges de ce dataset (raisons pour lesquelles on prend le CEMS)

1. **PAS DE PLUIE.** « Les variables accumulées sont omises (total precipitation, runoff...) ». → il faudrait un **2e dataset** (`reanalysis-era5-land` horaire) et agréger à la main.
2. **Le FWI se calcule à MIDI heure locale.** Ce dataset donne des **moyennes/max/min journaliers**, pas la valeur à 12h. Une option de décalage de fuseau existe, mais ça reste une approximation à documenter.
3. **L'agrégation est calculée à la volée**, pas archivée → **téléchargements lents**, files d'attente.

4.6 Calendrier

- `pip install holidays` → `holidays.France(years=range(1973,2025))`
- Vacances scolaires : `data.education.gouv.fr`
- ⚠ **Le découpage des zones A/B/C a changé plusieurs fois depuis 1973** → piège classique, à documenter

4.7 Référence externe — la Météo des forêts

Diffusée par Météo-France depuis 2023 : niveau de danger **par département**, pour **J+1 et J+2**, sur **4 niveaux** (faible/modéré/élevé/très élevé, vert/jaune/orange/rouge). Publiée chaque jour à 17 h.

Trois enseignements :

1. **Elle ne prédit pas les feux**, elle prédit **la dangerosité des conditions**. Météo-France est explicite : il n'est pas possible de prévoir les incendies, la plupart étant déclenchés par imprudence. **Fais tienne cette distinction** — elle t'évitera de promettre l'impossible.
2. **Granularité départementale, horizon 2 jours.** Toi : **commune × jour**, affiché à la semaine. → **C'est ton positionnement.**
3. Ses intrants (météo + occupation des sols + zones sensibles) **valident ta liste de features.**

5. Les 7 pièges mortels

🔥 Piège 1 — La fuite de données

Définition : une information qui **ne sera pas disponible au moment réel de la prédiction** se retrouve dans les features d'entraînement. **Symptôme** : des scores magnifiques. Ton code tourne, tes métriques sont superbes, tu es content. **Tu es en train de te planter**. **Analogie** : tu révises sur des annales avec le corrigé imprimé au dos. 20/20 en révision, 4/20 le jour J. Tu n'as pas appris la matière — **tu as appris à retourner la feuille**.

Fuite 1a — temporelle : le futur dans le passé

✗ `feux_voisins_20km` de la semaine 32/2021 **incluant** la semaine 32/2021. Un gros incendie brûle Fos **et** 4 communes voisines **la même semaine** → la feature vaut 4 *parce que* $y = 1$. Corrélation 0,95. PR-AUC 0,99. **Mais le 3 août 2026, tu ne sais pas combien de feux les voisins auront cette semaine — c'est le futur.**

✓ Semaines **28 à 31** uniquement — **strictement avant**.

Le test : « Le jour J, à 8 h du matin, est-ce que je connais cette valeur ? » Si non → fuite.

Fuite 1b — par le split : le test qui contamine le train

✗ `taux_voisin` calculé sur 1973–2024, puis split. Bormes-les-Mimosas → `taux_voisin = 0.45`, élevé **notamment à cause de 2023**. Ta ligne de 2015 « sait » que le Var va cramer en 2023.

✓ **L'ordre EST la solution** :

```
train = grille[grille.annee <= 2019] # 1. SPLIT D'ABORD
taux_voisin = train.groupby("cluster")["y"].mean() # 2. APPRENDRE sur train
seul → 0.31
grille["taux_voisin"] = grille.cluster.map(taux_voisin) # 3. APPLIQUER partout
```

Le mantra

« Je peux **appliquer** au test une statistique apprise ailleurs. Je ne peux **jamais calculer** une statistique en regardant le test. »

La question qui trie tout

« Pour calculer cette valeur, ai-je besoin de regarder d'AUTRES lignes que celle-ci ? »

	Transformation	Regarde d'autres lignes ?	Danger
✓	<code>sin(2π × jour/365)</code>	Non	Aucun
✓	<code>log(surface + 1)</code>	Non	Aucun
✓	<code>est_ferie(date)</code>	Non	Aucun
⚠	<code>StandardScaler</code>	Oui (μ , σ)	Fuite

Transformation	Regarde d'autres lignes ?	Danger
⚠ Imputation par la moyenne	Oui	Fuite
⚠ HDBSCAN, PCA	Oui	Fuite
🔥 <code>taux_voisin</code> , target encoding	Oui — moyenne de y !	Majeure
🔥 Lissage bayésien	Oui	Majeure

Règle mnémotechnique scikit-learn : si l'objet a une méthode `.fit()`, il est dangereux. `fit` = « j'apprends des données » = « je peux apprendre du futur ». **Ligne la plus rouge** : toute transformation qui utilise `y` est explosive.

Rappel — les 3 méthodes sklearn

Méthode	Ce qu'elle fait
<code>.fit(X)</code>	CALCULE μ et σ sur X et les mémorise . Ne transforme rien.
<code>.transform(X)</code>	APPLIQUE les μ/σ déjà mémorisés. Ne recalcule rien.
<code>.fit_transform(X)</code>	Les deux d'un coup. ⚠ C'est ce raccourci qui fait fuiter.

```
X_train, X_test = split(X, 2019) # 1. SPLITTER D'ABORD. Toujours.
scaler.fit(X_train)             # 2. APPRENDRE sur le train SEUL
X_train = scaler.transform(X_train) # 3. APPLIQUER
X_test = scaler.transform(X_test)  # 4. APPLIQUER – mêmes  $\mu/\sigma$ , on ne réapprend
PAS
```

`StandardScaler` = z-score colonne par colonne. Exactement ce que tu fais en STAPS quand tu dis « il est à +2 écarts-types de la moyenne au Wingate ».

Le garde-fou pratique

```
def build_features(grille, periode_reference):
    """periode_reference : (debut, fin) = SEULE période où on a le droit
    d'apprendre."""
    ref = grille[grille.annee.between(*periode_reference)]
    taux_voisin = ref.groupby("cluster")["y"].mean()
    return grille.assign(taux_voisin=grille.cluster.map(taux_voisin))

df = build_features(grille, periode_reference=(2006, 2019)) # ← jamais 2024
```

🔥 Le test du bon sens

Si ta PR-AUC dépasse 0,80 sur un événement à 0,3 % → ne te réjouis pas. **CHERCHE LA FUITE**. Elle est là. Un bon modèle sur ce problème fait **0,20 – 0,35**. C'est la vraie vie. Vérifie aussi tes SHAP : si une seule feature

écrase toutes les autres, elle est probablement une reformulation de la cible.

🔥 Piège 2 — Les arbres n'extrapolent pas

Structurel, pas un bug. Un arbre prédit une **constante** dans chaque boîte. Entraîné sur 20–38 °C, interrogé à 42 °C → il sort **exactement la valeur de 38 °C**.

Conséquence absurde et concrète : ton curseur « +4 °C » ne montrera **aucune aggravation dans le Var** (déjà au plafond du range) et une aggravation **dans le Nord** (qui entre dans le range). **L'inverse de la réalité.**

✅ **Parade retenue — GLM Poisson à lien log** :

$$\log(\lambda) = \beta_0 + \beta_1 \cdot T \quad \Leftrightarrow \quad \lambda = \exp(\beta_0 + \beta_1 \cdot T)$$

Le modèle est linéaire **dans le log**, donc **exponentiel dans le risque** → **il extrapole**, et il est **structurellement accélérant**. Avec $\beta_1 = 0,15$:

Scénario	Multiplicateur	
+1 °C	$e^{0,15} = \mathbf{1,16}$	+16 %
+2 °C	$e^{0,30} = \mathbf{1,35}$	+35 %
+4 °C	$e^{0,60} = \mathbf{1,82}$	+82 %

+4 °C ne fait pas le double de +2 °C : il fait le CARRÉ du multiplicateur ($1,35^2 = 1,82$). C'est exactement la non-linéarité que tu cherchais — **et elle est gratuite**, le lien log te la donne.

Options : ajouter un terme T^2 . ⚠️ Les **splines n'extrapolent pas bien** non plus → pour le curseur, reste sur log-link (+ éventuellement T^2).

🔥 Piège 3 — Le déséquilibre de classes

~0,2 % de positifs à la maille jour sur le périmètre méditerranéen.

- ❌ Jamais d'accuracy
- ✅ PR-AUC + Brier + courbe de calibration
- ✅ **Downsampling négatif ~1:10** (100 % des positifs conservés) → 880 k lignes, 30 s d'entraînement
- ✅ `is_unbalance=True` ou `scale_pos_weight` dans LightGBM
- ⚠️ **Ce qui compte, c'est le nombre ABSOLU de positifs (~80 000), pas le taux.** Le taux n'affecte que la métrique et la calibration.

🔥 Piège 4 — La calibration

Un modèle est **calibré** si, parmi toutes les cellules où il annonce 30 %, environ 30 % ont effectivement brûlé. (*La logique du « 70 % de chance de pluie ».*)

C'est distinct de la discrimination (savoir classer les risqués avant les autres). Un modèle peut très bien discriminer et être **totalelement décalibré**.

Tu affiches un score à l'utilisateur → la calibration n'est pas optionnelle.

- Mesure : courbe de calibration + **Brier score**
- Correction : **CalibratedClassifierCV** (isotonic ou Platt), **fittée sur le set de validation**
- 🎯 **Bonus** : si la validation n'est **PAS** downsamplee, la calibration **corrige automatiquement** le downsampling. Tu n'as pas à appliquer la formule de correction.

🔥 Piège 5 — Le biais de collecte BDIFF

Déjà connu, mais **à écrire noir sur blanc** dans le rapport. C'est le genre de lucidité qui sépare un projet d'étudiant d'un projet de professionnel — et c'est un réflexe que ta formation recherche t'a déjà donné : **interroger la validité de la mesure avant d'interpréter le résultat.**

🔥 Piège 6 — Le plancher de résolution de la mesure

Aucun modèle ne récupère une information que la mesure n'a pas capturée.

Si la date BDIFF est administrative ($\pm 1-2$ jours), un modèle au jour apparie le FWI du jour J à un feu du jour J-2. **Le signal se dilue — et rien dans tes métriques ne te le dira.** Tu verras juste un modèle « moyen » sans comprendre pourquoi.

C'est le même problème qu'un chronomètre à $\pm 0,5$ s avec lequel on prétend mesurer des effets de 0,2 s. Ce n'est **pas** une question de puissance statistique.

→ **Le test du dimanche (phase 2) est bloquant.** Il détermine ta granularité.

🔥 Piège 7 — L'agrégation temporelle destructrice

Si tu dois replier sur la semaine, **l'agrégation n'est pas la même selon l'indice** :

Indice	Comportement sur 7 j	✅ Agrégation
FFMC, ISI, FWI	Très volatils	max et mean — <i>un seul jour extrême suffit, la moyenne le dilue</i>
DC, DMC, BUI	Quasi constants (latence 12-52 j)	mean ou dernière valeur — <i>le max n'apporte rien</i>
Danger rating	Classe discrète	max — le pire jour

⚠️ **mean(FWI)** partout serait une **erreur silencieuse** : tu écraserais précisément le jour de canicule qui a déclenché l'incendie. → **Produis les deux** pour les volatils (**fwi_max**, **fwi_mean**). Laisse SHAP trancher. Coût : une colonne.

6. Feuille de route

Phase 0 — Cadrage 🕒 30 min

- ☐ 🚨 **Ouvrir les DEUX comptes Copernicus** (24 h de validation — en tout premier)
 - **EWDS** → <https://ewds.climate.copernicus.eu> (le FWI — la source principale)
 - **CDS** → <https://cds.climate.copernicus.eu> (la température — pour le curseur climat)
- ☐ Écrire **PROBLEM.md** (section 1)
- ☐ Créer le repo **terre-vent-feu-eau-data**

! Tu ne codes rien avant que **PROBLEM.md** existe.

Phase 1 — Ingestion 🕒 1 jour

- ☐ BDIFF : boucle de téléchargement par département (limite 30 k lignes)
- ☐ Corrections BDIFF + adaptation aux normes de recueil en vigueur
- ☐ **admin-express** (IGN) : contours + centroïdes + surfaces
- ☐ INSEE : densité de population
- ☐ 🌐 **cems-fire-historical-v1** (EWDS) → FWI, Danger rating, **Drought code**, FFMFC, DMC, BUI, ISI — NetCDF, système canadien
- ☐ ERA5-Land daily stats (CDS) → **uniquement 2m_temperature** (pour le curseur climat) + **volumetric_soil_water_layer_1**
- ☐ ❌ ~~Calcul du FWI maison~~ → **écarté** (cf. section 9)
- ☐ Calendrier : **holidays** + vacances scolaires
- ☐ Jointure spatiale : centroïde commune → maille 0,25° du CEMS

Phase 2 — 🌐 EDA d'abord 🕒 1/2 jour

La toute première figure du projet, avant tout modèle.

- ☐ 🚨 **LE TEST DU DIMANCHE — BLOQUANT** : feux par **jour de la semaine**
 - Creux le week-end → date **administrative** → 🚨 **repli sur la grille semaine**
 - Distribution plate → date d'**éclosion** → ✅ **la grille jour est validée**
 - ☐ Complément : pic anormal le 1er du mois → arrondi administratif ?
 - ☐ Lire les **métadonnées BDIFF** : quel champ ? Y a-t-il une heure ?
- ☐ **Feux par jour de l'année, 1973–2024** (365 points) → **le test du 14 juillet**
- ☐ **Spaghetti plot cumulé** : x = jour de l'année, y = **cumul** des surfaces brûlées, une courbe par année, dégradé bleu (1973) → rouge (2024)
 - *Pourquoi le cumul : les courbes brutes se croisent et c'est illisible. Le cumul est monotone → les courbes s'empilent et les années récentes se détachent. (Le graphique classique de la banquise arctique.)*
- ☐ **Heatmap année × jour** → la saison qui s'allonge + la ligne verticale du 14 juillet si elle existe
- ☐ **Ridgeline / joyplot par décennie** (`pip install joypy`) → le pic saisonnier qui se décale et s'élargit
 - *C'est la figure que Météo-France utilise pour dire que la saison pourrait durer 1 à 2 mois de plus. Toi, tu la montres **sur données réelles**.*
- ☐ **STL** sur la série agrégée → tendance / saisonnalité / résidu

- ☐ Documenter les biais et les ruptures de collecte

⚠ **Ces figures ne sont pas de la décoration avant les choses sérieuses.** Elles te disent quelles features construire, quel périmètre retenir, où sont les ruptures. Et en soutenance comme sur LinkedIn, **c'est ce que les gens regardent.** Un PR-AUC de 0,28 n'émeut personne. La heatmap 1973–2024, si.

Phase 3 — La grille 🕒 1 jour · **le cœur du projet**

⚠ **Ne commence pas avant le test du dimanche (phase 2).** Il détermine si tu bâtis au jour ou à la semaine.

- ☐ PostgreSQL + **PostGIS** (*pas SQLite : il te faut les jointures spatiales, et ça se conteneurise bien*)
- ☐ **Produit cartésien** *communes* × *jours* (~5 800 × 6 935 ≈ 40 M)
- ☐ **LEFT JOIN** BDIFF → *y* = 1 si feu, 0 sinon
- ☒ **Vérifier** : ~80 000 positifs, taux ≈ 0,20 %
- ☐ **Downsampling négatif ~1:10** → ~880 k lignes pour l'entraînement
 - ⚠ **Garde une validation NON échantillonnée** (elle sert à la calibration)
- ☐ Table de voisinage, calculée **une fois** :

```
CREATE TABLE voisins AS
SELECT a.code_insee AS commune,
       b.code_insee AS voisin,
       ST_Distance(a.geom::geography, b.geom::geography) AS dist_m
FROM communes a
JOIN communes b
  ON ST_DWithin(a.geom::geography, b.geom::geography, 50000)
 AND a.code_insee <> b.code_insee;
```

(~5 800 communes × ~200 voisins dans 50 km ≈ 1,2 M lignes. Une fois pour toutes.)

C'est ça, le vrai travail. Pas le HDBSCAN. C'est ça qui impressionnera un recruteur.

Phase 4 — Features 🕒 1,5 jour

- ☐ 🌀 **Jointure CEMS** ← **priorité n°1**, c'est là qu'est la performance
 - Centroïde commune → maille 0,25° → **6 indices journaliers** : FWI, FFMCI, DMC, DC, BUI, ISI + Danger rating
 - *Le FWI porte le QUAND (temporel). Tes features spatiales portent le OÙ. Division du travail propre — et c'est l'argument qui justifie les 28 km en soutenance.*
- ☐ **Décalage spatial** (⚠ **strictement t-1 et avant**) :

```
# nb de feux chez les voisins < 20 km, sur les 30 jours PRÉCÉDENTS
feux_voisins = (
    voisins.query("dist_m < 20000")
    .merge(grille, left_on="voisin", right_on="code_insee")
    .groupby(["commune", "date"])["nb_feux_30j_avant"].sum()
```

```
)
voisins["poids"] = 1 / (voisins["dist_m"] / 1000 + 1) # version pondérée
```

→ produit `feux_voisins_10km, _20km, _50km, feux_voisins_ponderes`

- ☐ **Lissage bayésien** (⚠ **fit sur train seul**) :

```
k = 10 # nb d'années fictives empruntées au voisinage – à calibrer sur la
validation
taux_lisse = (nb_feux + k * taux_voisin) / (n_annees + k)
# (0 + 10*0.40) / (30 + 10) = 0.10 au lieu de 0/30 = 0.00
```

C'est ton **effet aléatoire de modèle mixte** en STAPS. Un sujet avec peu de mesures voit son estimation tirée vers la moyenne du groupe. Ici, le « groupe » est géographique.

- ☐ **HDBSCAN** (⚠ **fit sur train seul**) — sur le **vecteur de features de risque**, **PAS** sur lat/lon seuls (sinon tu obtiens juste des paquets de communes proches : aucune information)
- ☐ **KDE** pour la heatmap (le bon outil pour la carte de chaleur — pas HDBSCAN)
- ☐ Cycliques : `sin/cos(2π × jour_julien/365)`
- ☐ 🗓 **Calendaires** — au jour, enfin : `est_ferie, est_weekend, jour_semaine, est_14_juillet, est_15_aout, vacances_scolaires` (zone A/B/C)
- ☐ Lags : feux dans la commune sur 7/30/90/365 jours
- ☐ Contexte : densité pop, surface, altitude, distance côte

Phase 5 — Baselines 🕒 1/2 jour · **non négociable**

- ☐ **Baseline 1 — spatiale** : fréquence historique lissée `commune × jour_de_1_année`
- ☐ 🗓 **Baseline 2 — météo : le Danger rating EFFIS tout seul**
- ☐ **Noter les deux scores.** Ton modèle doit battre **les deux**, sinon il ne sert à rien.

Réflexe direct de ta formation scientifique : pas d'effet sans groupe contrôle.

Pourquoi la Baseline 2 est stratégique

C'est LA question du jury : « à quoi sert votre modèle, puisque le FWI existe déjà ? » Avec cette baseline, la réponse est chiffrée et préparée :

« Le FWI seul atteint X de PR-AUC. Mon modèle atteint Y. Le gain vient de l'historique communal et du voisinage spatial — l'information que le FWI, par construction, ne contient pas : il est purement météorologique et ne sait rien de la végétation locale, de la fréquentation humaine, ni de l'historique du territoire. »

C'est ton positionnement en une phrase. Il découle directement de la nature de la Météo des forêts : elle prédit **la dangerosité des conditions**, pas l'événement. Ton modèle ajoute la **dimension territoriale**.

⚠ **Et s'il ne bat pas le FWI seul ?** Tu le dis. C'est un résultat légitime et publiable : la météo domine tout le reste — ce qui est cohérent avec le fait que Météo-France ne se base que sur ça.

Phase 6 — Modèles 🕒 1,5 jour

- ❑ **LightGBM** — le socle :

```
import lightgbm as lgb
model = lgb.LGBMClassifier(
    objective="binary",
    n_estimators=500,
    learning_rate=0.05,
    num_leaves=63,
    is_unbalance=True,          # ← le déséquilibre ~0,2 %
    random_state=42,
)
model.fit(X_train_downsampled, y_train_downsampled,
          eval_set=[(X_val, y_val)],      # ⚠ val NON échantillonnée
          eval_metric="average_precision") # = PR-AUC
```

- ❑ **GLM Poisson / Binomiale Négative** — interprétable + curseur climat
 - La **binomiale négative** est la version robuste quand la variance dépasse la moyenne (**surdispersion**) — ce sera ton cas.
- ❑ **Calibration** : **CalibratedClassifierCV** sur la validation **NON échantillonnée** → corrige le downsampling au passage
- ❑ **Agrégation affichage** : $1 - \prod(1 - p_j)$ sur 7 jours → **6 classes EFFIS** (seuils 5,2 / 11,2 / 21,3 / 38 / 50)
- ❑ Vérifier : **PR-AUC > 0,80** ⇒ **chercher la fuite**

🚨 **NE FAIS PAS de benchmark LightGBM vs XGBoost vs CatBoost.** L'erreur de débutant la plus coûteuse.

Levier	Gain réaliste
Features (IFM, voisinage, lissage, calendrier)	~80 %
Qualité des données (fuites, périmètre, biais)	~15 %
Choix de l'algo	~5 %
Hyperparamètres	~5 %

Même logique qu'en recherche : le protocole et la qualité de la mesure déterminent le résultat. Le choix du test statistique ne sauve jamais une mesure bancal.

Phase 7 — Interprétation 🕒 1/2 jour

- ❑ **SHAP uniquement**
- ❑ Vérifier qu'aucune feature n'écrase les autres (→ signal de fuite)
- ❑ Rédiger les insights

Phase 8 — Séries temporelles agrégées 🕒 1/2 jour (onglet tendance)

⚠️ **Les modèles de séries temporelles classiques ne s'appliquent PAS à ta grille creuse.** Une série temporelle = **une** suite de valeurs régulières. Ta grille = ~5 800 séries quasi-vides. **Ils s'appliquent aux séries AGRÉGÉES.**

- ☐ **Prophet** avec le paramètre **holidays** → il **quantifie l'effet du 14 juillet** avec un intervalle de confiance. 15 lignes de code. ★
- ☐ **SARIMAX** — le « X » permet d'injecter la température en exogène
- ☐ **STL** — déjà fait en EDA

Phase 9 — Application 🕒 1,5 jour

- ☐ Streamlit, **Onglet 1** : cartographie + filtres + stats descriptives + les figures de la phase 2
- ☐ Streamlit, **Onglet 2** : prédiction (commune + période → score + classe EFFIS)
- ☐ 🎨 **Palette officielle EFFIS** : #84F07F #FFEB3C #FFB00C #FA4F00 #B40000 #280923
 - Ta carte aura exactement les couleurs de l'EFFIS → reconnaissable au premier coup d'œil, crédibilité immédiate, zéro travail de design.
- ☐ **Curseur climat** +0/+1/+2/+4 °C (GLM Poisson)
- ☐ **Déploiement sur Streamlit Cloud** → **lien cliquable dans le post LinkedIn = 10× l'impact**

Phase 10 — Finalisation 🕒 1 jour

- ☐ Docker (en dernier — c'est de l'emballage)
- ☐ README technique + **requirements.txt**
- ☐ Rapport méthodologique (markdown)
- ☐ Section **limitations** (cf. section 9)
- ☐ Slides de soutenance

Phase 11 — Bonus, si et seulement si tout tourne 🟦

- ☐ **Processus de Hawkes** (`pip install tick` — Inria — ou **hawkeslib**)

7. Le bonus : Hawkes

Processus ponctuel auto-excitant : chaque événement **augmente temporairement la probabilité des événements suivants**, proches dans le temps et l'espace.

$$\lambda_i(t) = \underbrace{\mu_i}_{\text{risque de fond (végétation, climat, humains)}} + \underbrace{\sum g(t - t_j) \cdot h(d_{ij})}_{\text{excitation : chaque feu passé ajoute sa contribution, décroissante dans le temps ET dans l'espace}}$$

- μ_i = risque de fond de la commune

- $g(t - t_j)$ = décroissance **temporelle** — un feu d'il y a 2 jours excite fort, d'il y a 6 mois plus du tout $\approx \exp(-\beta \cdot \Delta t)$
- $h(d_{ij})$ = décroissance **spatiale** — un feu à 3 km excite fort, à 80 km non $\approx$ **noyau gaussien**

Pourquoi c'est LE modèle de ton intuition initiale — « une ville au milieu de villes qui prennent toujours feu, factuellement son risque est à 0 %, pourtant en réalité elle est très probablement exposée » :

Hawkes formalise ça nativement. Pas de bricolage de features : **la contagion EST l'équation**. Une commune à 0 feu historique entourée de feux récents aura une λ élevée **par le terme d'excitation**, même avec μ_i faible.

Et physiquement, un feu **est** auto-excitant : braises portées par le vent → départs secondaires ; même vague de chaleur ; même sécheresse ; même pyromane.

Sa généalogie te vend le concept toute seule : c'est le modèle **ETAS** des répliques sismiques, aussi utilisé en prédiction de criminalité. « J'ai appliqué aux feux le formalisme utilisé pour les répliques sismiques. » → **Ça, ça s'écoute.**

⚠ **Franchise** : c'est le morceau le plus exigeant mathématiquement du projet. **2–3 jours**. Ne le lance **que** si LightGBM tourne déjà.

8. Glossaire

Terme	Définition
Baseline	Modèle bête de référence. Sans elle, aucun score n'a de sens.
Binomiale négative	Régression de comptage robuste à la surdispersion
Brier score	Erreur quadratique moyenne sur des probabilités. Mesure la calibration.
Calibration	« Quand j'annonce 30 %, ça arrive 30 % du temps. » Distinct de la discrimination.
DBSCAN	Clustering par densité, eps global → inadapté à des densités variables
Discrimination	Savoir classer les risqués avant les non-risqués (PR-AUC)
ERA5-Land	Réanalyse météo Copernicus, grille 0,1°, 1950→, sans trou
ETAS	Modèle des répliques sismiques. Ancêtre de l'usage de Hawkes.
Fuite de données	Info indisponible le jour J présente à l'entraînement
GBDT	Gradient Boosting Decision Trees. Arbres en séquence , chacun corrigeant les erreurs des précédents.
HDBSCAN	DBSCAN hiérarchique . Plus de eps , juste min_cluster_size . Gère les densités variables.
IFM / FWI	Indice Forêt Météo. Agrège T°, humidité, vent, sécheresse. Calcul récursif .
KDE	Kernel Density Estimation. Le bon outil pour une carte de chaleur.

Terme	Définition
Lien log	$\log(\lambda) = \beta X \rightarrow$ réponse exponentielle , extrapole, accélérante
PR-AUC	Aire sous la courbe précision-rappel. La métrique en classes déséquilibrées.
Random Forest	Arbres indépendants , moyennés. (100 préparateurs qui ne se parlent pas.)
Shrinkage / lissage bayésien	Tirer une estimation vers la moyenne du groupe quand peu d'observations. = effet aléatoire
Small area estimation	Le nom du problème « commune à 0 feu entourée de brasiers »
Spatial lag	Features calculées sur les voisins
STGNN	Spatio-Temporal Graph Neural Network. Communes = nœuds, adjacence = arêtes.
Surdispersion	Variance > moyenne. Fréquent en comptage. $\rightarrow$ binomiale négative
z-score	$(x - \mu) / \sigma$. Ce que fait StandardScaler , colonne par colonne.

9. Ce qu'on a écarté, et pourquoi

🔴 **Section stratégique.** En soutenance, savoir dire « j'ai écarté X pour la raison Y, et voici ce que j'aurais fait avec plus de temps » vaut mieux que d'avoir tout survolé. **C'est exactement ce qu'on attend d'un professionnel.**

Écarté	Raison
Trafic routier	Difficile à obtenir au niveau communal, gain marginal. Déjà capté par densité de population.
SAGE + DiCE + LIME	Quatre méthodes d'interprétabilité = name-dropping, ça se voit. SHAP seul, bien exploité.
FastAPI + React	Deux fronts = deux livrables à moitié. Streamlit fini et déployé > les deux inachevés.
Analogie climatique	Élégant (« en 2050, Valence aura le climat d'Avignon aujourd'hui » $\rightarrow$ on transpose au lieu d'extrapoler, donc on ne sort jamais du domaine d'entraînement) — mais c'est un projet dans le projet . Le curseur GLM coûte 1/2 journée et fait 80 % du boulot pédagogique.
LSTM / ANN	ANN = pas de mémoire, battu par LightGBM sur tabulaire. LSTM = besoin de séquences denses ; 34 800 séquences à 99,7 % de zéros. Et le vrai driver est exogène (la météo), pas dans la séquence.
LSTNN / STGNN	La famille est conceptuellement parfaite (communes = nœuds d'un graphe, la diffusion est native). Mais LSTNN est conçu et validé sur du trafic routier : cible continue, signal dense à chaque pas, driver endogène . Toi : binaire, creux, driver exogène. Régime de données incompatible . Réactivable en agrégeant à département $\times$ semaine (96 nœuds, signal dense) — et alors commencer par STGCN ou DCRNN, pas LSTNN.

Écarté	Raison
Benchmark d'algos	2 jours pour 0,5 % d'écart pendant que la vraie perf dort dans un feature non construit
Stations Météo-France	Des points , pas une couverture → interpolation à bricoler. ERA5-Land est déjà une grille.
Calcul du FWI maison	Le produit officiel CEMS/EFFIS existe (GEFF-ERA5, 0,25°). Le gain 28 → 9 km est marginal pour une variable synoptique : la différenciation inter-communale est portée par les features spatiales, pas par la météo. Coût évité : 3 jours .

Phrases prêtes pour le README / la soutenance

« Le FWI a été récupéré depuis le produit officiel CEMS/EFFIS (GEFF-ERA5, 0,25°, Vitolo et al. 2020) plutôt que recalculé depuis ERA5-Land (0,1°). Le gain de résolution est marginal pour une variable synoptique, la différenciation inter-communale étant portée par les features spatiales. Un recalcul maison à 0,1° constitue une piste d'amélioration. »

« L'extrapolation hors du domaine d'entraînement est gérée par le lien log du GLM Poisson. Une approche par analogue climatique (transposition spatiale) serait plus robuste et constitue une piste d'amélioration. »

« Un STGNN a été envisagé : la formalisation en graphe correspond exactement à l'hypothèse de contagion spatiale. Il a été écarté pour incompatibilité de régime de données — la littérature STGNN est validée sur des signaux denses et endogènes (trafic routier), alors que les feux constituent un signal creux à driver exogène. »

⚠ **Le résultat négatif est un livrable.** Si un modèle bat LightGBM de 0,3 %, ou se fait battre : **écris pourquoi**. Ton parcours recherche te donne un avantage ici : **tu sais qu'un résultat négatif bien documenté est un résultat.**

10. Points de contrôle

#	Checkpoint	Critère de passage
1	PROBLEM.md écrit	5 lignes, sans ambiguïté sur unité / cible / métrique
2	Comptes CDS + EWDS validés	Deux cdsapi qui répondent
3	🔔 LE TEST DU DIMANCHE	Bloquant. Distribution plate → jour validé · Creux le week-end → repli semaine
4	La figure « 365 jours »	Le 14 juillet ressort ou non — une réponse, dans les deux cas
5	Grille construite	Lignes = communes × jours (~40 M). ~80 000 positifs , taux ≈ 0,20 %
6	Downsampling	~880 k lignes en train · validation NON échantillonnée conservée
7	Les 2 baselines scorées	Deux nombres noir sur blanc (historique lissé · Danger rating EFFIS)

#	Checkpoint	Critère de passage
8	LightGBM vs baselines	Il bat les DEUX ? Si non → features, pas hyperparamètres
9	Audit anti-fuite	PR-AUC < 0,80 ? SHAP sans feature dominante ?
10	Calibration	La courbe suit la diagonale
11	App déployée	Un lien public qui marche

11. Ta prochaine action

- 🔥 **Ouvrir les DEUX comptes Copernicus** — maintenant, il faut 24 h
 - EWDS → <https://ewds.climate.copernicus.eu> (le FWI, la source principale)
 - CDS → <https://cds.climate.copernicus.eu> (la température, pour le curseur climat)
- Écrire **PROBLEM.md** — 30 min, 5 lignes
- 🔥 **LE TEST DU DIMANCHE** — 1 h. **Il débloque toute l'architecture.**

```
bdiff.groupby(bdiff.date.dt.dayofweek).size().plot.bar()
# 0 = lundi ... 6 = dimanche
# Creux le week-end ? → date administrative → repli semaine
# Plat ? → date d'éclosion → le jour est validé
```

4. La figure des 365 jours — 2 h

Cette figure va soit confirmer ton hypothèse du 14 juillet — et là tu as ton accroche LinkedIn **dès le jour 1** — soit la démentir, et tu auras appris quelque chose de **vrai** sur tes données avant d'avoir écrit une ligne de modèle.

Une question, une figure, une réponse. Tu sais déjà faire ça, tu l'as fait en recherche. Le reste n'est que de l'outillage.

12. Journal des décisions renversées

(Pourquoi cette section existe : chaque ligne est une hypothèse que j'avais posée par défaut et que **tu** as fait tomber en posant la bonne question. C'est le meilleur indicateur de la santé du projet. Continue.)

Ce qui était acté	Ce qui l'a renversé	Leçon
<code>commune × semaine</code>	« Qui t'a dit que j'étais en semaine ? »	Un choix par défaut jamais validé, devenu faux quand la source météo a changé. Demande toujours qui a décidé quoi.
Calculer le FWI soi-même	Tu as trouvé le dataset et lu la fiche	Le produit officiel existait. Chercher avant de construire.

Ce qui était acté	Ce qui l'a renversé	Leçon
<code>total_precipitation</code> dans ERA5-Land daily	Tu as ouvert la page	Les variables accumulées sont omises. Lire la doc, pas la mémoire.
« Le dataset s'arrête en 2019 »	Tu as tiqué sur la date	C'était la date de publication de la fiche. Le réflexe était bon, la ligne était mauvaise.
Volumétrie = 0,03 % de positifs	Recalcul sur le vrai périmètre	0,20 %, et ~80 000 positifs. C'était un épouvantail.