

Terre, Vent, Feu, Eau, Data — rapport final et aide-mémoire

Document de référence, à consulter avant l'oral ou pendant, en cas de trou. Il n'est pas fait pour être lu de bout en bout : chaque section est autonome.

Tous les chiffres viennent des fichiers du dépôt, jamais de mémoire. Quand un chiffre figure ici, il est lisible dans [data/processed/*.csv](#) ou [app/donnees/meta.json](#).

Trouver vite

J'ai un trou sur...	Aller à
pourquoi la métrique n'est pas l'exactitude	§2.2
le sous-échantillonnage, le facteur 487	§2.3
ce qui est une fuite et ce qui n'en est pas	§2.4
le clustering, comment et sur quoi	§2.5
le lissage bayésien, la formule	§2.6
Platt, isotonique, à quoi ça sert	§2.7
le bootstrap apparié, la pseudo-réplication	§2.8
ADF, ACF, PACF, les axes	§2.9
SARIMAX et Fourier	§2.10
pourquoi le LSTM perd	§2.11
SHAP, LIME, DiCE	§2.12
les scénarios RCP	§2.14
pourquoi le modèle déployé est le moins bon	§3
les chiffres exacts d'un résultat	§5
une question que je crains	§6

1. Le projet en vingt chiffres

Communes de France métropolitaine	34 734
Lignes de la table centrale	253 731 870
Feux dans la grille (2006-2025)	49 130
Feux BDIFF sur le périmètre (1973-2025)	52 809

Taux de base	0,019 %
Cellules météo CEMS sur la France	1 131
Communes par cellule météo	~31
Variables du modèle déployé	41
Variables du meilleur modèle	52
Groupes du clustering	30 (+1 pour 2 communes atypiques)
Lift du modèle déployé, sur le test	×63,7
Lift du meilleur modèle, sur le test	×93,8
Écart LSTM contre modèle physique	−23,6 %
Régions gagnées en validation spatiale	9 sur 9
Hausse du FWI estival, 1973-2025	+62 % ($p = 1,5 \times 10^{-4}$)
Hausse du nombre de feux, 2006-2025	non significative
Communes n'ayant jamais brûlé	25 297 (73 %)
Rappel à 1 % de budget de surveillance	42 %
Tests automatisés	50
Date du gel avant test	28 juillet 2026

2. Les notions

2.1 L'événement rare, et pourquoi tout en découle

Un départ de feu concerne **0,019 %** des couples commune × jour. Une ligne sur 5 348.

Trois conséquences, et elles commandent tout le reste du projet :

1. **L'exactitude est inutilisable.** Répondre systématiquement « non » donne 99,98 % de justesse. Aucune métrique d'exactitude n'est présentée.
2. **Une fuite de données ne provoque pas d'erreur.** Elle produit d'excellentes métriques et un modèle sans valeur. Rien dans les scores ne la signale : c'est le risque principal.
3. **Le déséquilibre décide de la métrique, de l'échantillonnage, de la calibration et de la façon de comparer deux modèles.**

2.2 PR-AUC, ROC-AUC et lift

	ROC-AUC	PR-AUC
Mesure	vrais positifs contre faux positifs	précision contre rappel
Valeur au hasard	0,50 toujours	le taux de base

ROC-AUC	PR-AUC
À 0,019 % de positifs flatteuse, 0,95 sans effort	lisible

La ROC-AUC compare les positifs aux négatifs. Quand les négatifs sont 5 348 fois plus nombreux, ajouter des faux positifs ne bouge presque pas le taux de faux positifs — donc la courbe reste belle même pour un modèle médiocre.

La PR-AUC vaut exactement le taux de base quand on répond au hasard. D'où :

$$\text{lift} = \text{PR-AUC} \div \text{taux de base}$$

« Combien de fois mieux que tirer au sort. » C'est le seul nombre du projet qui se dise à voix haute sans être trompeur.

2.3 Le sous-échantillonnage et le prior déplacé

Ce qu'on fait. On retire des négatifs du train. On n'ajoute jamais rien, on ne duplique jamais rien.

sql/31_split.sql :

```
WHERE split <> 'train' -- val et test INTÉGRAUX : jamais échantillonnés
OR y -- 100 % des positifs du train
OR u < 0.00187; -- 0,187 % des négatifs du train
```

L'arithmétique. Taux de base 0,0187 % → environ 5 348 négatifs par positif. Pour un ratio 1:10, garder 10/5 348 = **0,187 %** des négatifs.

La conséquence. Le modèle apprend sur un jeu à 9,1 % de positifs alors que la réalité est à 0,019 %. Le rapport, **×487**, c'est simplement 9,1 / 0,019. Le classement reste bon, mais le niveau absolu des probabilités est faux.

Les trois garde-fous.

1. Validation et test ne sont **jamais** échantillonnés : les scores restent comparables au monde réel.
2. Les statistiques dérivées de la cible se calculent sur le train **complet**. Sur l'échantillon, un lissage bayésien vaudrait 9,1 % au lieu de 0,019 % : le prior serait empoisonné et rien ne le signalerait.
3. **u** est un tirage **déterministe** : le même échantillon est reproduit à chaque exécution.

2.4 Le split temporel et la fuite

Train **2006-2019**, validation **2020-2022**, test **2023-2025**.

Pourquoi jamais aléatoire. Un tirage au hasard mettrait le 14 juillet 2019 dans le train et le 15 dans le test. Le modèle « prédirait » un feu qu'il a déjà vu, à 20 km et un jour d'écart. La métrique serait excellente et le modèle sans valeur.

La règle qui tranche les cas douteux :

Une variable **datée** peut regarder tout le passé, y compris celui de sa propre période d'évaluation. Une statistique **non datée** ne peut regarder que le train.

L'exemple qui la rend claire. « Feux des 30 jours précédents » au 3 août 2023 lit juillet 2023 : ce n'est **pas** une fuite, parce que le 3 août à 8 h du matin on connaît juillet. En revanche « taux moyen de la commune sur toute la période » lit le futur : c'en est une.

Le test. Ouvert **une seule fois**, après gel complet du modèle, des variables et de la calibration, le 28 juillet 2026. Aucune décision n'en découle. La justification : le risque d'un jeu de test est **cumulatif**, chaque coup d'œil en apprend un peu et les décisions suivantes en sont insensiblement informées.

2.5 Le clustering territorial

Le problème. Le modèle v1 tirait 54,6 % de son importance de l'historique de la commune. Il disait surtout « ce qui a brûlé rebrûlera ». Conséquence : une commune qui n'a jamais brûlé gardait un score bas, même entourée de communes qui brûlent chaque été. C'est le problème classique d'**estimation sur petits domaines** (*small area estimation*) : trop peu d'événements pour estimer un taux commune par commune.

Sur quoi porte le clustering. Des caractéristiques **physiques** : végétation, relief, densité humaine, climatologie du FWI, position. **Jamais sur la cible.** Un cluster construit sur la sinistralité serait circulaire — on prédirait le feu avec des groupes définis par le feu.

La position est sous-pondérée à 25 %. Sans latitude et longitude, les groupes seraient éclatés d'un bout à l'autre du pays. À poids plein, ils dégénéreraient en pavés géographiques et le clustering ne serait qu'un découpage administratif déguisé.

La configuration. k-means, $k = 30$, $n_init = 10$, $random_state = 42$. Deux communes n'ont pas de profil exploitable : elles vont dans un cluster **-1** et reçoivent le prior national. D'où **31 valeurs distinctes** dans les données pour 30 vrais groupes.

Les trois garde-fous anti-fuite.

1. Le profil ne lit que le passé : CORINE 2006, climatologie FWI 2006-2019.
2. Les taux sont agrégés sur le train **complet**, jamais sur l'échantillon.
3. Pour une ligne de train de l'année Y, les taux **excluent l'année Y**. Sans ça une ligne de 2012 contribuerait à sa propre variable : c'est la fuite classique du *target encoding*. Les lignes de validation et de test utilisent les 14 années de train, dont elles ne font pas partie.

2.6 Le lissage bayésien

Le problème. Une commune sans feu en 5 113 jours a un taux observé de **0**. Ce n'est pas une estimation, c'est une absence d'information.

La formule, hiérarchique national → cluster → commune :

$$\text{taux_commune} = (\text{nb_feux} + K_1 \times \text{taux_du_cluster}) / (\text{nb_jours} + K_1)$$

avec $K_1 = 2\ 000$ et, un cran au-dessus, $K_0 = 20\ 000$ pour ramener le taux du cluster vers le taux national.

Comment lire K. C'est un nombre de jours fictifs. $K_1 = 2\ 000$ signifie « je ne fais pleinement confiance au comptage d'une commune qu'au-delà d'environ 2 000 jours d'observation ». Chaque commune ayant exactement 5 113 jours de train, le poids du groupe vaut $2\ 000 / (5\ 113 + 2\ 000) = 28,1\ %$.

Mesuré sur les données réelles, pour les 25 297 communes (73 % du pays) qui n'ont jamais brûlé :

taux_commune_lisse	de $6,07 \times 10^{-7}$ à $9,18 \times 10^{-4}$
Combien valent zéro	0 sur 25 297
Rapport entre la plus basse et la plus haute	1 512×

Le lissage ne leur colle donc pas une valeur par défaut identique : une commune de garrigue corse sans historique hérite du taux de son groupe méditerranéen, une commune de Picardie hérite du sien.

Le gain mesuré : +0,83 % de PR-AUC. Réel mais modeste, et le dire fait partie du résultat.

2.7 La calibration : Platt et isotonique

Le problème. Le modèle sort un **score**, pas une probabilité. À cause du sous-échantillonnage, ce score est **145 fois trop grand** : il annonce 93 % là où la réalité est 3 %.

Calibrer, c'est apprendre une fonction qui transforme le score en probabilité.

	Comment	Effet
Platt	ajuste une sigmoïde, 2 paramètres	lisse, monotone, garde les 9 millions de valeurs distinctes
Isotonique	ajuste une fonction en escalier croissante	très souple, mais écrase à 136 valeurs distinctes

Les deux corrigent aussi bien le biais : $\times 144,7 \rightarrow \times 1,13$ pour Platt. Mais l'isotonique détruit du pouvoir de discrimination pour rien — si 300 communes partagent exactement le même score, on ne peut plus les classer entre elles.

Ni l'un ni l'autre n'est utilisé dans l'application. Elle affiche un **rang**, parce que le calibrateur disponible a été ajusté sur un autre modèle et une autre période : il serait faux d'un facteur voisin de 2. On a préféré ne pas afficher de probabilité plutôt que d'en afficher une fausse.

2.8 Le bootstrap apparié

Le problème. v3 fait 0,0177 de PR-AUC, DART 0,0174. Est-ce un vrai écart ou le hasard de l'échantillon d'évaluation ?

Apparié : on tire un échantillon et on évalue **les deux modèles sur exactement les mêmes lignes**. On répète 200 fois. On obtient 200 écarts, donc une distribution **de l'écart** — pas deux distributions séparées qu'il faudrait ensuite comparer.

On rééchantillonne les communes, pas les lignes. C'est le point de méthode le plus important du projet.

Les 1 096 jours d'une même commune ne sont pas indépendants, et 31 communes partagent la même maille météo — elles voient le même FWI. Le nombre d'informations réellement indépendantes est bien plus petit que 38 millions. Tirer ligne à ligne reviendrait à traiter 38 millions d'observations comme 38 millions d'expériences indépendantes : les intervalles seraient **beaucoup trop étroits** et feraient conclure à des différences inexistantes. Le terme consacré est la **pseudo-réplication**.

L'astuce de calcul. Recalculer la PR-AUC 200 fois sur 38 millions de lignes coûterait des heures, chaque appel retriand le tableau. On trie **une fois** ; une réplique n'est alors qu'un jeu de **poids entiers** le long de cet ordre figé, et la précision moyenne pondérée se calcule en une passe par sommes cumulées. Vérifié identique à scikit-learn à 1×10^{-12} près.

2.9 Stationnarité, ACF et PACF

ADF — test de Dickey-Fuller augmenté. Il teste la présence d'une racine unitaire.

H_0 : la série **a** une racine unitaire, donc elle **n'est pas** stationnaire. Rejeter H_0 ($p < 0,05$) signifie **stationnaire**.

C'est l'inverse de l'intuition, et c'est la confusion la plus fréquente sur ce test.

ACF et PACF — les axes.

- **Ordonnée** : un coefficient de **corrélation**, entre -1 et $+1$, sans unité.
- **Abscisse** : le **retard, en jours**.
- **Bande bleue** : le seuil de significativité, $\pm 1,96/\sqrt{n}$. Une barre qui reste dedans est indiscernable de zéro.

La différence entre les deux. L'ACF au retard 2 mesure la corrélation entre aujourd'hui et avant-hier, en incluant tout ce qui transite par hier. La PACF retire cet effet indirect : elle donne **l'apport propre** du retard 2.

C'est donc la PACF qui répond à « combien de jours de passé faut-il garder ».

Les valeurs mesurées, sur les résidus du cycle annuel, 7 305 jours :

Retard	ACF	PACF	Significatif
1 jour	0,697	0,697	oui
2 jours	0,584	0,191	oui
3 jours	0,501	0,077	oui
4 jours	0,435	0,041	oui
7 jours	0,315	0,014	non
8 jours	0,295	0,034	oui

Seuil : $\pm 0,023$.

La nuance à donner soi-même. Les retards 4 à 8 restent *statistiquement* significatifs. Avec 7 305 points le seuil descend à 0,023 et presque tout le devient. Mais le retard 8, à 0,034, rend compte de **0,11 %** de la variance. **Significatif ne veut pas dire utile.** Le retard 7 non significatif entre deux qui le sont est d'ailleurs le signe qu'on est dans le bruit.

2.10 SARIMAX

La série modélisée : nombre de communes-jours en feu, par jour. Moyenne 6,73, maximum 89 le 18 juillet 2022.

Pourquoi pas SARIMA avec $s = 365$. Une saisonnalité annuelle sur données journalières demanderait d'estimer des coefficients à 365 pas de distance sur 5 113 points d'ajustement : instable et très lent. La pratique établie est de porter la saisonnalité par des **termes de Fourier en variable exogène** — quelques harmoniques suffisent pour un cycle annuel lisse. Le projet en utilise 4 paires sinus/cosinus. C'est le « X » de SARIMAX.

Les résultats. MAE en communes-jours par jour, sur une moyenne de 6,73 :

Modèle	MAE	r
SARIMAX(2,0,1) + Fourier + FWI	4,03	0,850
SARIMAX(2,0,1) + Fourier seul	6,42	0,603
ARIMA(2,0,1) sans exogène	8,34	-0,118
Référence : moyenne du jour de l'année	5,13	0,598

La ligne qui compte est la troisième. Un ARIMA sans variable exogène donne une corrélation **négative**. À 1 096 pas d'horizon, un modèle autorégressif dont la mémoire utile vaut trois jours a oublié son point de départ et converge vers la moyenne ; la ligne plate qu'il produit se trouve légèrement anti-corrélée à l'observé.

Ajouter le FWI fait tomber l'erreur de 37 %. **La prévisibilité du feu est dans la météo, pas dans son propre passé.**

Gain sur la référence saisonnière naïve : +21,5 % de MAE. Ce n'est pas un triomphe, et c'est le point.

2.11 Le LSTM, et pourquoi il perd

Ce qu'il a reçu. 30 jours $\times$ 8 indices météo = 240 valeurs par exemple. 25 essais Optuna, arrêt précoce à l'époque 21. Hyperparamètres retenus : 2 couches, cache 32, tête 256, dropout 0,179, lr $7,8 \times 10^{-4}$, lot 2 048. L'objection « il n'a pas été réglé » ne tient pas.

Contre qui le comparer. Pas contre v3 : v3 voit l'historique des feux (29 % de ses importances), le LSTM n'en voit rien. Les opposer mesurerait le prix de l'information retirée, pas la valeur de la séquence. **La seule référence à jeu d'information égal est le modèle C.**

Le résultat : **-23,6 %**, intervalle [-33,5 ; -17,3]. Loin de zéro.

L'explication, physique. Un LSTM sert quand l'ordre de la séquence porte une information qu'aucun résumé ne capture. Ici ce résumé existe déjà : les indices **DC**, **DMC** et **BUI** du système canadien **sont** des états récurrents. Le *Drought Code* est une moyenne exponentielle de la météo passée avec une constante de temps de **52 jours**, le *Duff Moisture Code* de **15 jours**. C'est la forme d'une cellule récurrente, à ceci près que ses coefficients ont été calibrés par cinquante ans de science du feu plutôt qu'estimés sur 9 176 exemples positifs.

Le CEMS livre déjà l'état caché que le LSTM devrait réapprendre.

Trois méthodes indépendantes concordent : la PACF (mémoire utile de deux à trois jours), l'ARIMA sans exogène (corrélation négative), et les importances du modèle C (les trois premières variables disent où est le combustible, pas quand).

La réserve à donner spontanément. Le LSTM ne reçoit pas **danger_effis**, qui pèse 13,7 % dans le modèle C. Les 23,6 % sont donc un **majorant**. C'est la première chose à reprendre.

2.12 SHAP, LIME, DiCE

Trois outils, trois questions différentes.

	Question	Nature
SHAP	pourquoi ce score ?	exact sur un modèle d'arbres
LIME	pourquoi ce score ?	approché, substitut linéaire local
DiCE	qu'aurait-il fallu changer ?	contrefactuel

SHAP. Décompose un score en contributions par variable, selon les valeurs de Shapley de la théorie des jeux. Sur un modèle d'arbres, **TreeSHAP est exact** : il parcourt la structure des arbres en temps polynomial, il n'échantillonne pas. Vérifié dans le projet — la somme des contributions plus la valeur de base redonne le logit du score à $9,5 \times 10^{-7}$ près.

Trois mesures d'importance qui ne donnent pas le même classement :

1. **Le gain d'entraînement** : combien la variable a réduit la perte. Sortie par défaut de XGBoost. Biaisée vers les variables qui découpent proprement, **aveugle à la redondance**.
2. **SHAP sur échantillon aléatoire** : l'effet sur le territoire tel qu'il est, soit 99,97 % de communes-jours sans feu. Lecture pour « en général ».
3. **SHAP au sommet du classement** : l'effet là où le modèle s'engage. Lecture pour « quand ça brûle ».

Deux désaccords à savoir expliquer.

- **danger_effis** est **2^e par gain** et **30^e par SHAP**. C'est une discrétisation du FWI en six classes : XGBoost trouve ces seuils commodes pour découper, d'où un gain élevé, mais l'information est déjà dans le FWI continu et SHAP en attribue le crédit à ce dernier.
- **part_maquis** est **1^{er} par gain**, **10^e** sur l'échantillon aléatoire et **2^e** au sommet. Sur une commune-jour moyenne il n'y a pas de maquis, donc la variable ne déplace rien ; là où le modèle voit du risque, elle devient déterminante.

Conséquence pratique : citer « la variable la plus importante » n'a pas de sens sans préciser quelle mesure et sur quelle population.

LIME. Perturbe le point, interroge le modèle des milliers de fois, ajuste une régression linéaire pondérée sur ce voisinage. Ce qu'il rend, ce sont les coefficients d'un **modèle de substitution**, pas la contribution exacte. Trois conséquences : les variables apparaissent sous forme de **règles** (**fwl** > 12,4), le résultat est **stochastique**, et il dépend du **fond** fourni. Sur un modèle d'arbres, il approxime ce que TreeSHAP calcule exactement : il ne peut pas faire mieux. Il redeviendrait le bon outil sur un modèle qu'on ne peut pas ouvrir, une API ou un réseau profond.

DiCE. Cherche le point le plus proche que le modèle classerait différemment.

Le détail d'implémentation qui change tout : DiCE cherche par défaut à faire passer la probabilité sous **0,5**. Or le score n'est pas calibré — 0,5 correspond à un risque astronomique et l'outil ne renvoyait **jamais rien**. On a recentré la frontière sur le **décile**, par une transformation affine par morceaux strictement croissante qui laisse le classement intact. La question devient « que faudrait-il pour sortir des 10 % les plus à risque », celle qui a un sens opérationnel.

Le résultat sur Bormes-les-Mimosas, 12 août 2024, en n'autorisant que la végétation : **aucun contrefactuel**. Rien, sur ces leviers, ne l'en fait sortir. Son exposition tient à sa position, à son relief, à sa superficie. Le risque est **structurel**, et l'absence de solution est ici la réponse.

La mise en garde : un contrefactuel n'est pas une recommandation. Rien ne garantit qu'il soit réalisable — on ne convertit pas 40 % de maquis en terres agricoles — ni que le lien soit **causal** : le modèle a appris des corrélations sur 2006-2019, pas des mécanismes.

2.13 Le biais de collision

Un **collider** est une variable causée par deux autres. Conditionner dessus crée une association artificielle entre ces deux causes.

Dans ce projet : sélectionner les lignes sur le **score** du modèle est un conditionnement sur un collider — le score est causé à la fois par la météo et par le territoire. En analysant l'interaction météo × territoire sur le seul sommet du classement, **le signe de l'interaction s'inversait**.

C'est pour cette raison que le panneau « sommet » ne se lit que pour la question « quand ça brûle », jamais pour « quelle est la relation entre A et B en général ».

2.14 Les scénarios RCP

RCP = *Representative Concentration Pathway*. Le chiffre est le **forçage radiatif en 2100, en W/m²**.

Hypothèse	
RCP 2.6	neutralité carbone vers 2070
RCP 4.5	émissions plafonnées vers 2040
RCP 8.5	aucune politique climatique

Ce qu'on projette : le FWI, seule quantité qui montre un signal et seule que les modèles climatiques savent fournir.

Ce qu'on ne projette pas : le nombre de feux. La végétation, la prévention et les pratiques agricoles sont supposées **constantes**, ce qui est une hypothèse, et elle est fausse.

Ce que « le 2 août 2050 » signifie : pas une prévision météo, mais un 2 août **ordinaire** sous le climat de 2050. La forme de la saison vient des observations 2006-2019, seul son niveau est décalé.

Avant 2045, les trois scénarios sont indiscernables. Mesuré : en 2030, le RCP 2.6 dépasse le RCP 8.5 sur **59 %** des communes. Ce n'est pas une anomalie du code, c'est l'inertie du système climatique — les trajectoires d'émissions ne divergent réellement qu'après le milieu du siècle. L'application grise cette zone sur les graphiques.

3. Les choix, et pourquoi

Choix	L'alternative	Pourquoi ce choix
Grille dense commune × jour, 253 M lignes	garder la seule liste des 52 809 feux	une série creuse rend les fenêtres glissantes silencieusement fausses : « feux des 30 jours précédents » se calcule en remontant 30 lignes, et sans les jours sans feu on remonte plusieurs années
PostgreSQL + PostGIS , partitionné par année	tout en Parquet	le partitionnement par année rend le split temporel exact et les requêtes d'évaluation peu coûteuses ; PostGIS pour le rattachement commune → maille et la distance à la côte
Split temporel	split aléatoire	un split aléatoire met le 14 juillet dans le train et le 15 dans le test
PR-AUC	ROC-AUC, exactitude, F1	seule métrique dont la valeur au hasard est le taux de base, donc seule interprétable à 0,019 %
Sous-échantillonnage 1:10 du train seul	pondération des classes, SMOTE	177 M lignes sont ingérables ; SMOTE interpolerait des communes-jours qui n'existent pas, sur des variables physiques dont les combinaisons ont un sens
Fichier officiel INSEE pour les fusions	rapprochement par le nom	le nom produit des faux positifs — « Chirac » en Lozère renvoyait vers la Charente. 935 feux rattachés avec certitude, 30 écartés et comptés , jamais devinés
Modèle C déployé malgré ×63,7 contre ×93,8	déployer v3	v3 dépend de l'historique des feux, que la BDIFF ne publie pas pour l'année en cours ; en territoire inconnu la variable vaut zéro et se lit « ça ne brûlera pas » ; pour 2050 elle est impossible par construction
Rang affiché , pas une probabilité	afficher la probabilité calibrée	le calibrateur disponible a été ajusté sur un autre modèle et une autre période, il serait faux d'un facteur ~2. Mieux vaut pas de probabilité qu'une fausse
Bootstrap sur les communes	bootstrap sur les lignes	pseudo-réplication : les jours d'une commune ne sont pas indépendants, 31 communes partagent une maille météo
Pas d'ensemble malgré +2,0 %	déployer v3 + MLP	casse la chaîne SHAP et double la chaîne de service pour un gain qui ne se voit pas opérationnellement
Fourier en exogène	SARIMA d'ordre 365	365 pas de distance sur 5 113 points : instable et très lent
Palette EFFIS par défaut , alternative accessible	EFFIS seule	la palette officielle n'est pas monotone en luminance : le jaune « faible » (0,810) est plus clair que le vert « très faible » (0,688), donc les deux premières classes se lisent à l'envers en protanopie et deutéranopie

4. L'architecture technique

Les sources.

Source	Contenu	Volume
CEMS · Copernicus	8 indices de danger, par jour et par maille de 0,25°	21,9 M lignes, 1973-2025
BDIFF · IGN	feux déclarés, commune par commune	52 809 feux
CORINE Land Cover	occupation du sol, 44 postes	1,08 M lignes
INSEE	référentiel communal et mouvements de communes	34 734 communes

La chaîne. Docker → PostgreSQL 16 + PostGIS 3.4 (port 5433) → 20 partitions annuelles → vues de split → matrice d'apprentissage en Parquet → modèles → artefacts CSV/JSON → [app/donnees/](#) → Streamlit.

Les modèles.

Modèle	Variables	Ce qu'il teste
Baselines (3)	0	ce que valent des règles sans apprentissage
XGBoost v1	43	un gradient boosting standard suffit-il
XGBoost v2	43	le problème du v1 est-il un problème de réglage
XGBoost v3	52	peut-on donner un risque aux communes sans historique
DART	52	l'abandon d'arbres améliore-t-il la généralisation
MLP	52	un réseau dense fait-il mieux que des arbres
XGBoost C	41	que reste-t-il sans aucun historique de feu
LSTM	30 j × 8	la séquence météo porte-t-elle un signal propre

Les 41 variables du modèle C : 11 météo, 12 occupation du sol, 7 territoire, 11 calendrier. Aucune dérivée de l'historique des feux.

Hyperparamètres XGBoost (Optuna, TPE, 60 essais) : `n_estimators` 900, `learning_rate` 0,0117, `max_depth` 10, `min_child_weight` 25, `subsample` 0,695, `colsample_bytree` 0,603, `gamma` 1,03, `reg_lambda` 0,0226, `reg_alpha` 0,0627.

Qualité. 50 tests automatisés en intégration continue à chaque commit, dont deux dédiés au split et à l'absence de fuite. DVC pour les données lourdes. Gel documenté dans [data/processed/gel_avant_test.json](#).

5. Tous les résultats

La grille.

Partition	Années	Lignes	Feux	Taux
train	2006-2019	177 594 942	33 632	0,0189 %

Partition	Années	Lignes	Feux	Taux
validation	2020-2022	38 068 464	9 176	0,0241 %
test	2023-2025	38 068 464	6 322	0,0166 %
total	2006-2025	253 731 870	49 130	0,0194 %

Les baselines, sans aucun apprentissage.

Prédicteur	PR-AUC	lift
hasard	0,000241	×1,0
historique de la commune	0,004668	×19,4
danger EFFIS seul	0,001220	×5,1
historique × EFFIS	0,010149	×42,1

Les modèles sur la validation (38 068 464 lignes, 9 176 feux).

Modèle	PR-AUC	lift	vs v3	IC 95 %	Significatif
XGBoost v3	0,0177	×73,4	référence		
DART	0,0174	×72,0	−1,8 %	[−5,0 ; +0,8]	non
MLP	0,0173	×71,9	−1,9 %	[−7,9 ; +5,2]	non
XGBoost C	0,0112	×46,4	−36,8 %	[−43,8 ; −24,0]	oui
LSTM	0,0085	×35,4	−51,7 %	[−57,2 ; −43,4]	oui

Ensemble v3 + MLP : 0,0180, ×74,9. Non retenu. **LSTM contre modèle C**, à information égale : **−23,6 %** [−33,5 ; −17,3].

Le test, ouvert une fois.

Modèle	PR-AUC	lift
XGBoost v3	0,0156	×93,8
XGBoost C (déployé)	0,0106	×63,7

Par année : 2023 ×75,6 (2 591 feux) · 2024 ×151,4 (1 297 feux) · 2025 ×87,0 (2 434 feux). **Le lift suit la rareté** : une année calme concentre les feux dans les endroits les plus prévisibles.

Validation croisée spatiale : le modèle physique gagne **9 régions sur 9**, +8,2 % en moyenne pondérée, jusqu'à **+137 %** dans le Grand Est.

Rendement opérationnel, sur le test.

Budget	Communes-jours suivis	Feux couverts	Part des feux
0,1 %	38 068	924	14,6 %

Budget	Communes-jours suivis	Feux couverts	Part des feux
1 %	380 684	2 650	41,9 %
10 %	3 806 846	5 372	85,0 %

Les 37 % de PR-AUC qui séparent v3 du modèle C ne valent que **3 points de rappel à 1 % de budget**, et **rien du tout à 10 %**.

Le climat.

Série	Période	Variation	p	Verdict
FWI moyen annuel	1973-2025	+58 %	$4,2 \times 10^{-5}$	significatif
FWI juin-septembre	1973-2025	+62 %	$1,5 \times 10^{-4}$	significatif
jours de danger élevé	1973-2025	+197 %	$5,2 \times 10^{-5}$	significatif
communes-jours en feu	2006-2025	+3 %	0,89	non significatif

Les modèles secondaires. Surface brûlée : R^2 0,144, MAE 3,94 ha — moins bon que d'annoncer toujours la médiane. Grand feu (seuil 5 ha) : PR-AUC 0,232, lift 2,88, ROC-AUC 0,766.

La distance à la côte, mesurée sur les données observées :

Distance	Feux par commune	Feux par 1 000 km ²
0-10 km	10,26	519
25-50 km	3,77	200
100-200 km	0,87	55
200+ km	0,36	25

Une commune côtière brûle **28 fois plus** qu'une commune de l'intérieur. C'est un **proxy géographique** — climat sec et venteux, maquis et pins, fréquentation estivale — pas un mécanisme.

6. Questions d'expert

6.1 Un data engineer

Pourquoi PostgreSQL et pas simplement du Parquet ou DuckDB ? Pour le partitionnement par année, qui rend le split temporel exact au niveau du stockage, et pour PostGIS — le rattachement commune → maille météo et la distance à la côte sont des opérations géométriques. Le Parquet intervient après, pour la matrice d'apprentissage, là où on relit toujours les mêmes colonnes.

253 millions de lignes, quelle taille et quel temps de construction ? 20 partitions annuelles.

data/processed pèse 2,6 Go, les artefacts servis à l'application 112 Mo. La grille se construit en SQL, pas en Python : c'est ce qui rend l'opération tenable.

Votre échantillonnage est-il reproductible ? Oui, `u` est un tirage déterministe stocké, pas un `random()` évalué à chaque requête. Le même échantillon ressort à chaque exécution.

Que se passe-t-il si Copernicus republie des données corrigées ? Le chargement est idempotent par période. En revanche la climatologie 2006-2019 et les clusters devraient être recalculés, et le gel avant test serait invalidé — il faudrait repartir d'un nouveau gel.

Vous avez eu un incident de qualité de données ? Oui, le plus coûteux du projet. `sql/50_matrice.sql` n'a pas d'`ORDER BY` : l'ordre des 38 millions de lignes que renvoie PostgreSQL dépend du plan d'exécution et **change d'une exécution à l'autre**. Mes fichiers de prédictions ne portaient que `(score, cible)` — même taille, même nombre de feux, ordre différent, aucune exception levée. Le premier verdict du LSTM annonçait -97% au lieu de -52% . Depuis, **tout fichier porte ses clés** `(code_insee, date)`, une fonction d'alignement vérifie, et un test **refuse** un fichier sans clés.

Comment est-ce testé ? 50 tests en intégration continue à chaque commit, dont un qui reproduit volontairement le désalignement : on permute les lignes, la PR-AUC tombe de 0,0085 à 0,0002, exactement la ligne du hasard, avec les mêmes valeurs dans le fichier.

6.2 Un data analyst

Pourquoi le taux de feu diffère-t-il entre train (0,0189 %), validation (0,0241 %) et test (0,0166 %) ? Ce sont des périodes différentes, avec des étés différents. 2022 a été exceptionnel — le maximum de la série est le 18 juillet 2022 avec 89 communes-jours en feu. C'est aussi pourquoi le lift varie du simple au double selon l'année du test.

La BDIFF est-elle exhaustive ? Non, et le projet le documente. La couverture n'est pas la même selon les départements et les périodes, et **64 % des causes déclarées sont manquantes**. C'est une limite de la **cible**, pas seulement des variables : elle borne ce qu'on peut prétendre mesurer.

Comment avez-vous vérifié la qualité des dates BDIFF ? Par un « test du dimanche » : si la date enregistrée était une date de saisie administrative plutôt qu'une date d'éclosion, on verrait un déficit le week-end. Le contrôle figure dans `figures/data-bdiff/01`.

Pourquoi deux saisons de feu ? Le pic d'août est méditerranéen. Le pic de mars concerne le Sud-Ouest et le Massif central, sur des landes et herbacées sèches avant la reprise de végétation, souvent des écobuages qui échappent. En **part** de leurs feux hors saison estivale : Cantal 52 %, Dordogne 44 %, Lozère 41 %. En **volume** absolu, la Haute-Corse, la Gironde et l'Hérault dominant, y compris hors été — confondre les deux lectures est une erreur facile.

Une commune-jour, c'est un incendie ? Non. Un feu traversant cinq communes compte cinq fois. La cible est « cette commune a-t-elle au moins un départ déclaré ce jour-là », pas « combien d'incendies ».

Que valent les communes qui n'ont jamais brûlé ? 73 % du pays, 25 297 communes. Leur taux lissé va de $6,1 \times 10^{-7}$ à $9,2 \times 10^{-4}$, **aucune n'est à zéro**, et l'étendue est d'un facteur 1 512.

6.3 Un data scientist

Pourquoi 1:10 et pas 1:1 ou 1:100 ? Compromis entre volume d'entraînement tenable et déformation du prior. À 1:1 le prior serait déplacé d'un facteur 5 000 et la calibration deviendrait l'essentiel du travail ; à 1:100

le train resterait à 3,6 millions de lignes positives-négatives, coûteux pour un gain marginal. Le choix n'a pas été optimisé — c'est une limite assumée.

Pourquoi pas SMOTE ou de la pondération de classe ? SMOTE interpole entre exemples pour créer des positifs synthétiques. Ici les variables sont physiques et leurs combinaisons ont un sens : interpoler entre une commune corse et une commune picarde produit un territoire qui n'existe pas. La pondération, elle, ne réduit pas le coût de calcul, qui était le problème.

Comment évitez-vous la fuite du target encoding ? Pour une ligne de train de l'année Y, les taux **excluent l'année Y**. Sans ça une ligne de 2012 contribuerait à sa propre variable. Les lignes de validation et de test utilisent les 14 années de train, dont elles ne font pas partie.

Vos variables météo sont fortement redondantes — BUI est une fonction de DMC et DC. Pourquoi les garder toutes ? Parce que les arbres gèrent la redondance sans dommage pour la prédiction, et que le projet mesure cette redondance plutôt que de l'ignorer : c'est exactement ce qui explique que **danger_effis** soit 2^e par gain et 30^e par SHAP. Une paire redondante n'invalide pas le modèle, elle invalide la lecture naïve de l'importance par gain.

Pourquoi 200 répliques de bootstrap ? Au-delà, la largeur des intervalles ne bouge plus de façon utile et le coût est linéaire. Les conclusions n'en dépendent pas : les intervalles qui traversent zéro le traversent largement.

Vos intervalles traversent zéro pour DART et le MLP. Est-ce un manque de puissance ? C'est possible et je ne peux pas l'exclure. Ce que je peux affirmer, c'est que **avec ce protocole et ces données je ne peux pas les départager**. Dire « XGBoost bat le MLP » serait une conclusion tirée du bruit. La lecture la plus probable est que le signal disponible est capté de façon comparable par les trois familles, et que la limite est dans les données.

Pourquoi pas de validation croisée ? Parce que le découpage doit rester temporel. Une validation croisée classique mélangerait les années. Le projet fait en revanche une **validation croisée spatiale** : on retire une région entière, on entraîne, on teste sur la région exclue, neuf fois.

Votre modèle déployé est le moins performant. Ce n'est pas contradictoire ? Non, parce que la performance est mesurée dans des conditions qui n'existent pas en production. v3 a toujours l'historique des feux en validation comme en test ; il ne l'aurait pas demain matin. Le défaut n'apparaît dans **aucune métrique d'entraînement** : il ne se voit qu'en se demandant ce que deviendrait le modèle en service. Et l'écart coûte 3 points de rappel à 1 % de budget, rien à 10 %.

Comment savez-vous que le modèle n'a pas simplement appris la géographie ? Il n'a ni latitude ni longitude. La carte qu'il produit retrouve pourtant les Landes, l'arc méditerranéen et la Corse, à partir de la végétation, du relief et du littoral. Et la validation croisée spatiale montre qu'il **transfère** à des régions retirées de l'entraînement.

TreeSHAP est exact, dites-vous. Vous l'avez vérifié ? Oui : la somme des contributions plus la valeur de base redonne le logit du score à $9,5 \times 10^{-7}$ près.

6.4 Mise en production, MLOps

À quelle fréquence faut-il réentraîner ? Le modèle C ne dépend d'aucune donnée qui bouge en cours d'année. Un réentraînement annuel, quand CORINE ou le référentiel communal changent, suffirait. C'est un

avantage direct du choix de déploiement.

Comment détecteriez-vous une dérive ? Sur les entrées, en surveillant la distribution des 8 indices CEMS par mois contre la climatologie 2006-2019. Sur les sorties, en comparant le rappel à budget fixe d'une année sur l'autre. Ce n'est pas en place — c'est une limite.

Quelle est la latence d'un calcul quotidien ? Le modèle score 34 734 communes en une passe ; le coût est dominé par le chargement des contours, pas par l'inférence. L'application met environ deux minutes à démarrer à froid, essentiellement pour charger les polygones.

Le modèle est-il utilisable par un SDIS demain matin ? Pas en l'état. Il donne un **classement national par jour**, ce qui répond à « où regarder en priorité », mais il n'est pas calibré en probabilité, il ne tient pas compte des moyens disponibles, et il n'a pas été évalué en conditions opérationnelles. Ce qu'il fournit est une aide au ciblage.

6.5 Questions pièges

« **Votre modèle est fiable à 99,98 %, c'est ça ?** » Non, et c'est précisément le piège que la rareté tend. Répondre toujours « non » donne 99,98 %. Le nombre à retenir est le lift : **63,7 fois mieux que le hasard**.

« **Donc les feux augmentent avec le changement climatique ?** » Mes données ne le montrent pas. Les conditions **favorables** aux feux augmentent très significativement — FWI estival +62 %, jours de danger élevé +197 %. Le nombre de départs, lui, ne montre **aucune tendance significative** sur les 20 années dont je dispose. Trois lectures restent possibles : faible puissance statistique sur 20 points, prévention qui absorbe pour l'instant la hausse de l'aléa, ou déplacement vers des feux plus grands plutôt que plus nombreux. **Je ne peux pas trancher, et je ne le ferai pas.**

« **Votre carte montre où il brûlera en 2050 ?** » Elle montre l'**aléa météo** sous le climat de 2050, appliqué à un jour ordinaire. Pas le nombre de feux, pas la localisation des incendies. La végétation et la prévention y sont supposées constantes, ce qui est faux.

« **XGBoost bat donc le MLP.** » Non. Leurs intervalles de confiance se recouvrent : **je ne peux pas les départager**.

« **Pourquoi ne pas utiliser simplement le FWI, qui existe déjà ?** » Parce qu'il vaut ×5 le hasard seul, contre ×42 croisé au territoire. Le FWI est l'entrée principale du modèle, pas son concurrent. Ce que le projet ajoute, c'est une résolution spatiale : à l'intérieur d'une maille de 28 km on trouve 31 communes qui reçoivent aujourd'hui le même indice, qu'elles soient couvertes de maquis ou bétonnées.

« **Les communes voisines d'un feu ont donc un risque nul ?** » Non. Mesuré sur Appietto (Corse-du-Sud) le 12 août 2024 : ses **40 communes voisines dans 20 km qui n'ont pas brûlé** ont toutes un score non nul, un rang médian de 375^e sur 34 734, et **les 40 sont dans le décile le plus à risque**. Le modèle déployé n'a pourtant aucune variable d'historique : elles remontent parce qu'elles partagent la maille météo et la végétation.

« **Et la propagation de proche en proche entre communes ?** » Elle n'est pas dans le projet. La variable est conçue et écrite (`sql/41_feat_voisinage.sql.reporte`), la table de voisinage est chargée, mais la requête n'a jamais été exécutée et aucun modèle n'a de colonne `feux_voisins_*`. C'est la première extension prévue. Ce qui joue ce rôle aujourd'hui est le clustering, où la proximité est une **ressemblance physique** et non une adjacence géographique.

« **Si vous aviez trois mois de plus ?** » Dans l'ordre : donner `danger_effis` au LSTM pour lever l'asymétrie de la comparaison, refaire une calibration propre sur le modèle déployé et la bonne période, livrer la feature de voisinage, et chercher une source de cause de départ moins lacunaire que 64 % de manquants.

« **Quelle erreur vous a coûté le plus cher ?** » Le désalignement des lignes, parce qu'il ne lève aucune exception et donne un résultat plausible. J'ai failli conclure que le LSTM perdait de 97 %.

7. Ce que le projet ne fait pas

Limite	Chiffre
La surface brûlée n'est pas prédictible	R^2 0,144, moins bon que la médiane constante
« Sera-ce un grand feu » se prédit mal	lift 2,88 contre 63,7 pour les départs
Une commune-jour n'est pas un incendie	un feu sur 5 communes compte 5 fois
31 communes partagent une maille météo	les intervalles naïfs sur les coefficients météo seraient trop étroits
Le LSTM n'a pas reçu <code>danger_effis</code>	les 23,6 % sont un majorant
La BDIFF n'est pas homogène	64 % de causes manquantes, couverture variable
Pas de détection de dérive en production	non implémenté
38 communes sans contour cartographique	code changé entre le millésime du fond et le COG 2026

Sur la ROC-AUC de 0,766 du modèle « grand feu » : elle est exacte, mais s'en servir après avoir expliqué pourquoi la ROC-AUC flatte serait se contredire. Le chiffre honnête sur cette tâche est le lift de 2,88.

8. Glossaire

Terme	Définition
FWI	<i>Fire Weather Index</i> , indice synthétique du système canadien
FFMC	humidité de la litière fine, 1-2 cm, mémoire courte
DMC	<i>Duff Moisture Code</i> , 5-10 cm, constante de temps 15 jours
DC	<i>Drought Code</i> , 10-20 cm, constante de temps 52 jours
BUI	<i>Build-Up Index</i> , combustible disponible, fonction de DMC et DC
ISI	<i>Initial Spread Index</i> , vitesse de propagation
ERC	<i>Energy Release Component</i> , énergie libérable par unité de surface
KBDI	<i>Keetch-Byram Drought Index</i> , sécheresse du sol
PR-AUC	aire sous la courbe précision-rappel ; vaut le taux de base au hasard

Terme	Définition
lift	PR-AUC ÷ taux de base
ACF	autocorrélation : corrélation entre t et $t-k$, effets indirects compris
PACF	autocorrélation partielle : apport propre du retard k
ADF	Dickey-Fuller augmenté ; H_0 = racine unitaire = non stationnaire
SARIMAX	ARIMA saisonnier avec variables exogènes
DART	<i>Dropouts meet Multiple Additive Regression Trees</i> : boosting où 10 % des arbres sont éteints à chaque itération, une itération sur deux
SHAP	décomposition exacte d'un score en contributions, valeurs de Shapley
LIME	substitut linéaire local, approché
DiCE	génération de contrefactuels
Pseudo-réplication	traiter des observations corrélées comme indépendantes
Biais de collision	conditionner sur une variable causée par deux autres, ce qui crée une association artificielle entre elles
Small area estimation	estimer une quantité sur des domaines à trop peu d'observations
RCP	<i>Representative Concentration Pathway</i> , forçage radiatif en 2100 (W/m ²)

9. Commandes

Relancer la comparaison de modèles, puis remettre le support et la vitrine d'aplomb :

```
python -m tvfed.comparer && python -m tvfed.vitrine
```

Relancer l'analyse de séries temporelles (ADF, ACF/PACF, SARIMAX) :

```
python -m tvfed.series
```

Lancer l'application en local :

```
streamlit run app/Carre.py
```

Faire tourner les tests :

```
pytest tests/ -q
```

⚠ `python -m tvfed.diaporama` réécrit `presentation/soutenance.pptx` **entièrement**. Le fichier de travail a été étendu à la main (clôture et annexe de captures) : régénérer effacerait ces diapositives.