


Terre, Vent, Feu, Eau, Data

– suite : Industrialisation de l'Intelligence Incendie –

Surveillance des risques de feux de forêt en France



"Les forêts précèdent les peuples, les déserts les suivent."

– François-René de Chateaubriand

Contexte pédagogique

Le présent projet constitue la suite du projet du même nom, et le prolonge pour renforcer les livrables en vue d'une industrialisation.



Mise en situation professionnelle

Mission Professionnelle, contexte de l'Équipe Projet

Après le succès de votre Proof of Concept (POC), la **Direction Générale de la Sécurité Civile et de la Gestion des Crises (DGSCGC)** a décidé de prolonger votre mission de deux semaines.

L'exigence a changé : il ne s'agit plus seulement de démontrer que l'on peut "voir" les incendies passés, mais de bâtir une **solution industrielle robuste** capable de prédire le risque quotidien avec une précision accrue en intégrant des facteurs environnementaux dynamiques . Vous agissez en tant qu'équipe de consultants juniors devant livrer un produit prêt pour une mise en pré-production.

Objectifs Techniques et Méthodologie

Votre mission consiste à **transformer le pipeline initial en une chaîne MLOps** de bout en bout, allant de l'ingestion multi-sources à l'inférence explicable.

A. Data Engineering : Acquisition et Ingestion

Le défi majeur de cette phase est la fusion de données hétérogènes.

Consolidation SQL : Vous devez renforcer votre base de données pour supporter des jointures massives sur le code INSEE et la date.



Intégration Météo : Vous devez collecter des données historiques (température, vent, humidité) via des sources open data (ex: *MeteoNet* ou *ERA5*).

Note sur le géocodage : Les stations météo ne coïncident pas avec les centres des communes. Vous devrez utiliser une *méthode d'interpolation spatiale* (plus proche voisin ou moyenne pondérée par la distance) pour attribuer des valeurs météorologiques à chaque commune.

Échantillonnage (Negative Sampling) : Pour que le modèle apprenne à distinguer les situations à risque, vous ne devez pas vous limiter aux points de données contenant des incendies: vous devez générer des "points négatifs" : **pour chaque commune et pour chaque jour de la période d'étude, créez une ligne indiquant l'absence de feu (Cible=0) avec les conditions météo associées.**

B. Feature Engineering et Clustering

Variables Cycliques : Pour que le modèle comprenne la continuité du temps, implémentez un encodage cyclique (sin et cos) pour les jours et les mois . N'hésitez pas à créer aussi des variables pour indiquer si une journée est en semaine, en weekend, en période de vacances scolaires, afin de repérer des patterns périodiques dans certains départs de feu.

Clusters comme Features : Utilisez des algorithmes de clustering spatial (DBSCAN ou HDBSCAN) avant l'entraînement de vos modèles. Identifiez les zones géographiques à forte densité de risque historique et **injectez l'identifiant du cluster comme une "feature" catégorielle** dans votre modèle pour capturer la contagion géographique.



Features de Vélacité : Calculez les moyennes mobiles de température et de pluviométrie sur les 7, 15 et 30 derniers jours pour capturer l'effet de sécheresse cumulée et le lag (délai entre une période de sécheresse et les pics de risque d'incendie).

.

C. Pipeline d'Entraînement et MLOps

Architecture Modèle : Reprenez vos anciens modèles, et continuez votre travail avec des réseaux de neurones (ANN/MLP) construits avec Keras ou PyTorch pour modéliser les relations non linéaires complexes .

Hypertuning avec Optuna : Automatisez la recherche des meilleurs hyperparamètres (learning rate, nombre de couches, dropout) via la bibliothèque Optuna.

Split Temporel : **N'utilisez pas de K-Fold classique!** Respectez strictement l'ordre chronologique (par exemple, train sur 2006-2021, test sur 2022-2024) pour éviter le data leakage temporel

.

Métriques de Validation : Compte tenu du déséquilibre des classes (les feux restent des événements rares), privilégiez la Précision, le Rappel sur la classe "Feu" et l'AUPRC (Area Under the Precision-Recall Curve) plutôt que l'accuracy globale.

.

Ordre des Tâches (Roadmap)



Semaine 1 : Data Ops & Engineering

- Mise en place de l'environnement Docker et de la structure Git
- Ingestion BDIFF + Ingestion Météo et création du dataset d'entraînement (positif + négatif).
- Calcul des features géo-temporelles et des clusters spatiaux.
- Versionnage des données avec DVC

Semaine 2 : Science & Industrialisation

- Entraînement des réseaux de neurones (MLP) avec suivi des expériences (logs).
- Optimisation via Optuna et validation sur le split temporel.
- Intégration de SHAP pour l'explicabilité (identifier l'influence du vent ou de l'humidité, ou toute autre variable, sur chaque score)
- Développement du frontend Streamlit (dashboards cartographiques + simulateur de risque)
- Configuration du pipeline CI/CD (GitHub Actions) pour automatiser les tests unitaires

Livrables Attendus

- GitHub documenté : incluant le code source, le fichier requirements.txt et le fichier DVC pour la reproductibilité
- Image Docker : contenant l'application Streamlit et le modèle entraîné prêt à l'emploi



- Note de Cadrage Technique (document markdown dans votre dépôt GIT): expliquant les choix d'architecture (ANN, clustering) et les résultats obtenus (métriques AUPRC/Rappel)

- Application Streamlit fonctionnelle : présentant une carte de densité de risque et un module de prédiction par commune incluant l'explication SHAP

La réussite du projet repose sur votre capacité à démontrer que le modèle ne se contente pas de "mémoriser" les feux passés, mais qu'il généralise le risque en fonction de la dynamique météo actuelle.